

INFOTEC CENTRO DE INVESTIGACIÓN E
INNOVACIÓN EN TECNOLOGÍAS DE LA
INFORMACIÓN Y COMUNICACIÓN

DIRECCIÓN ADJUNTA DE INNOVACIÓN Y
CONOCIMIENTO
GERENCIA DE CAPITAL HUMANO
POSGRADOS

Un enfoque para la detección y eliminación de artefactos en señales de electroencefalografía a través de técnicas de aprendizaje profundo con adaptación de dominio

PROTOCOLO DE INVESTIGACIÓN

Presenta:

**M. en C. Emmanuel de Jesús Velásquez
Martínez**

Asesor:

Dr. Miguel Ángel Porta García

Aguascalientes, Mayo 2025

Resumen

Las redes neuronales artificiales profundas son modelos capaces de resolver tareas de regresión y de clasificación, y han ganado popularidad en la mayoría de los campos de investigación. Sin embargo, estos modelos han mostrado dificultades para generalizar al realizar la misma tarea en entornos ligeramente diferentes de aquellos en los que fueron entrenados, lo que provoca que estas herramientas de apoyo sean deficientes en escenarios reales. En el campo del procesamiento de señales se encuentran tanto señales estacionarias como no estacionarias. Estas últimas pueden presentar variabilidades, impidiendo que una red neuronal generalice sin sobreajustar el modelo. Una de las señales no estacionarias es la señal EEG, la cual presenta un nivel considerable de ruido al momento de adquirirla desde el cuero cabelludo. Además, este ruido se incrementa cuando el cuerpo realiza movimientos oculares, musculares o cuando el electrodo sufre algún tipo de interferencia, lo que provoca distorsiones en la señal EEG y dificulta su interpretación en el ámbito clínico o en las interfaces cerebro-computadora. Otro de los problemas que enfrentan las redes neuronales artificiales es que requieren ser entrenadas con una cantidad de datos considerablemente grande para alcanzar una buena capacidad de generalización. Asimismo, el elevado número de parámetros impide que este tipo de modelos se pueda implementar en hardware de bajo costo. Por ello, este estudio tiene como objetivo proponer un modelo que, tanto en tareas de clasificación como en las de regresión, sea capaz de generalizar en dos dominios distintos, permitiendo obtener un mejor rendimiento. Además, se busca que dicho modelo pueda inferir en hardware de bajo costo, haciéndolo apto para aplicaciones en tiempo real. En este trabajo se propone desarrollar un modelo de red neuronal artificial para abordar tres problemas principales: (a) Problema de generalización en distintos conjuntos de datos; (b) problema de regresión y clasificación para la identificación y eliminación de artefactos; (c) problema de implementación del modelo en hardware de bajo costo para la toma de decisiones en tiempo real. El propósito es mejorar la robustez en la identificación y eliminación de artefactos fisiológicos y no fisiológicos y utilizar la solución en tiempo real.

Índice general

Índice de figuras	5
Índice de cuadros	6
Índice de Algoritmos	7
Siglas y Abreviaturas	8
Protocolo de investigación	1
1.1. Introducción	1
1.2. Antecedentes	2
1.2.1. Bases neurofisiológicas de la generación de señales EEG y la medición del EEG	2
1.2.2. ¿Cómo el EEG viaja desde el cerebro hasta el dispositivo de registro?	4
1.2.3. Redes neuronales artificiales	6
1.2.4. Adaptación de dominio en redes neuronales artificiales	7
1.2.5. EEG con artefactos y conjunto de datos	9
1.2.6. Extracción de características en EEG	15
1.2.7. Métricas de evaluación	18
1.3. Estado del arte	24
1.4. Plantamiento del problema	34
1.5. Marco de trabajo	35
1.6. Justificación	36
1.7. Preguntas de investigación	37
1.8. Objetivo general	38
1.8.1. Objetivos particulares	38
1.9. Hipótesis	38
1.10. Alcance	39
1.11. Contribuciones	39

1.12. Cronograma de actividades	40
1.13. Materiales y métodos	40
1.13.1. Propuesta de solución al plantamiento del problema	41
1.14. Resultados parciales	44
1.15. Conclusiones parciales	49

Bibliografía	61
---------------------	-----------

Índice de figuras

1.1. Medición de dipolos radiales y tangenciales. Fuente: (Jackson & Bolger, 2014).	3
1.2. Disposición paralela y la actividad sincrónica que permite que la señal sea medida en el cuero cabelludo. Fuente: (Jackson & Bolger, 2014). a: Las señales negativas se sumaran y seran medibles en el cuero cabelludo. b: Las señales positivas y negativas se cancelaran entre sí en cuero cabelludo, por lo tanto no seran medibles. c: No surge un dipolo claro de la disposición aleatoria de las cargas positivas y negativas, por lo que no se medira ninguna señal en el cuero cabelludo.	4
1.3. La pila de capacitadores con del de electrodo, mostrando la propagación de la señal neuronal a través de las capas del cerebro, duramadre, caneo y gel del electrodo hasta llegar al electrodo. Fuente: (Jackson & Bolger, 2014).	6
1.4. Arquitectura de red neuronal artificial	7
1.5. Ejemplos de señal EEG y EEG con varios tipos de artefactos.	11
1.6. Transformada de Fouerier en Tiempo Corto	16
1.7. Marco de trabajo propuesto para la clasificación, detección e eliminación de artefactos en señales de EEG. Los bloques se dividen en preprocesamiento de señales de EEG, extracción de características, evaluación del modelo propuesto y desarrollo de una herramienta de visualización en tiempo real.	36
1.8. Arquitectura de red neuronal implementada y método de entrenamiento de adaptación de dominio para tareas de clasificación y regresión	43
1.9. Comportamiento de exactitud durante el entrenamiento de la red neuronal con adaptación de dominio (dominio fuente y dominio objetivo con los conjuntos de entramiento y validación).	45
1.10. Comportamiento de Divergencias y Distancias entre Distribuciones a lo largo de las Épocas del Entrenamiento de la Red Neuronal.	46

1.11. Matriz de confusión del dominio fuente en el conjunto de validación en la detección de artefactos.	50
1.12. Matriz de confusión del dominio objetivo en el conjunto de validación en la detección de artefactos.	50
1.13. Visualización multicanal de señales EEG con etiquetas de artefactos. . . .	51
1.14. Inferencias y visualización multicanal de señales EEG con etiquetas de artefactos en una Raspberry Pi.	51

Índice de cuadros

1.1. Cantidad de artefactos por tipo del Corpus TUH EEG	15
1.2. Comparativa de métodos de detección y/o eliminación de artefactos en señales EEG.	33
1.3. Cronograma de actividades	40
1.4. Resultados por clase del dominio fuente	48
1.5. Resultados por clase del dominio objetivo	48
1.6. Comparación del promedio de exactitud entre diferentes métodos.	48

Índice de Algoritmos

1.	Generación de señal sintética EEG con componentes sinusoidales, envolvente gaussiana y ruido	12
2.	Agregado sintético de artefactos a la señal EEG	14
3.	Adaptación de dominio para tareas de clasificación y regresión no supervisada usando la pérdida de Sinkhorn - TO [1]	42
4.	Cálculo de pérdida Sinkhorn	43

Siglas y Abreviaturas

10-20	Sistema internacional de colocación de electrodos
ANN	Red Neuronal Artificial
BCI	Interfaces Cerebro-Computadora
BiGRU	Unidad Recurrente con Puertas Bidireccional
CC	Coeficiente de Correlación
CHEW	Artefacto de Masticar
CNN	Red Neuronal Convolucional
DA	Adaptación de Dominio
dB	Decibelios
EEG	Electroencefalografía
ELPP	Artefacto de Explosión de Electrodo
EMG	Artefacto Muscular
EOG	Artefacto Ocular
GAN	Red Neuronal Adversarial Generativa
IDFT	Transformada Discreta de Fourier Inversa
LSTM	Red Neuronal Memoria a Corto-Largo Plazo
MAE	Error Absoluto Medio
MSE	Error Cuadrático Medio
RNN	Red Neuronal Recurrente
RMSE	Raíz del Error Cuadrático Medio
RRMSE	RMSE Relativo
SHIV	Artefacto de Mareo
SNR	Relación Señal-Ruido
STFT	Transformada de Fourier de Tiempo Corto
TO	Transporte Óptimo

Protocolo de investigación

1.1. Introducción

El rápido desarrollo tecnológico ha impulsado un creciente interés científico en el uso de datos biomédicos, ya que estos abarcan distintas áreas como la comunicación, el control del movimiento, la interacción con el entorno y la neurorrehabilitación, entre otras [2]. Esto conlleva a la necesidad de realizar un análisis de dichos datos, lo cual requiere de un preprocesamiento adecuado para extraer los patrones deseados que permitan su correcta interpretabilidad [3]. En este trabajo se plantea aportar en el análisis de las señales de electroencefalograma (EEG) en cuanto la detección y eliminación de artefactos en este tipo de señales. Para introducirnos en las señales EEG, es importante mencionar que estas se utilizan para el diagnóstico, monitoreo y pronóstico de afecciones neurológicas [4] y para aplicaciones en el campo de las interfaces cerebro-computadora (BCI) [5]. El registro de las señales EEG se realiza mediante un método no invasivo que genera una señal compleja para el estudio de la actividad eléctrica cerebral, a través de la colocación de electrodos en el cuero cabelludo del paciente, abarcando distintas áreas del cerebro [6], en este caso se usa el sistema 10-20 el cual garantiza que cubra todas las regiones de la zona frontal, occipital, temporal y parietal [7]. Un EEG se produce como consecuencia del voltaje eléctrico generado por las neuronas cerebrales [8]. Debido a su baja amplitud, esta señal se ve fácilmente alterada por diversos artefactos. El estudio y análisis de las señales cerebrales en presencia de estos artefactos es una tarea compleja. Al ser un método no invasivo, se presentan desafíos, ya que la señal EEG puede verse afectada por una amplia gama de ruidos no estacionarios, tanto por artefactos fisiológicos relacionados con el movimiento del propio cuerpo como por artefactos no fisiológicos ocasionados por el movimiento o la interferencia del equipo de sensado [9]. El principal problema de los distintos tipos de artefactos es que pueden afectar significativamente el análisis de los datos y el diagnóstico [10].

El presente protocolo de investigación se encuentra estructurado en la sección

Introducción donde se presenta un contexto general del tema. En los antecedentes se abordan las bases de EEG, las redes neuronales artificiales, definición de adaptación de dominio, conjuntos de datos EEG, métodos de extracción de características y métricas de evaluación. El estado del arte se abordan investigaciones de diversos autores. Después continúa con el planteamiento del problema y el marco de trabajo. En la sección de justificación se argumenta la importancia del estudio. Posteriormente se abordan las preguntas de investigación, el Objetivo general, los objetivos particulares y la hipótesis donde se formulan las suposiciones a evaluar. El alcance delimita el contenido del trabajo, y las contribuciones identifican los aportes esperados. El cronograma de actividades organiza las tareas por realizar, mientras que los resultados parciales y las conclusiones donde se tienen los avances obtenidos.

1.2. Antecedentes

En la presente sección se introduce el marco teórico que se estará usando en la presente investigación, esto con el fin de comprender los distintos conceptos y técnicas a utilizar durante el desarrollo de esta investigación.

1.2.1. Bases neurofisiológicas de la generación de señales EEG y la medición del EEG

Las señales de electroencefalografía (EEG) surgen a partir de la actividad sináptica sincronizada en poblaciones de neuronas corticales las cuales son células piramidales organizadas a lo largo de columnas corticales. El proceso ocurre a través de la excitación de las neuronas postsinápticas que crea un voltaje extracelular cerca de las dendritas neuronales que es más negativo que en otras partes de la neurona. Esta situación se conoce como dipolo, el cual es una región de carga positiva separada de una región de carga negativa que se denomina sumidero. Los electrodos detectan la suma de cargas positivas y negativas en su entorno. En el caso de que un electrodo esté a la misma distancia de la fuente y el sumidero de un dipolo, el electrodo medirá un valor neto neutro. Por lo tanto, un electrodo puede detectar dipolos cuando está más

cerca de uno de los extremos positivo o negativo del dipolo. Esto significa que hay dos principales tipos de dipolos medibles en el EEG: los dipolos tangenciales (ver figura 1.1 (a)) los cuales están orientados perpendicularmente a la superficie, y los dipolos radiales (ver figura 1.1 (b) y (c)) que se encuentran ubicados paralelamente a la superficie del cuero cabelludo. Los dipolos tienen un lado positivo y uno negativo, por lo que se producirán una deflexión positiva y otra negativa en diferentes regiones del cuero cabelludo como se muestra en la figura 1.1 (c) [11], [12], [13].

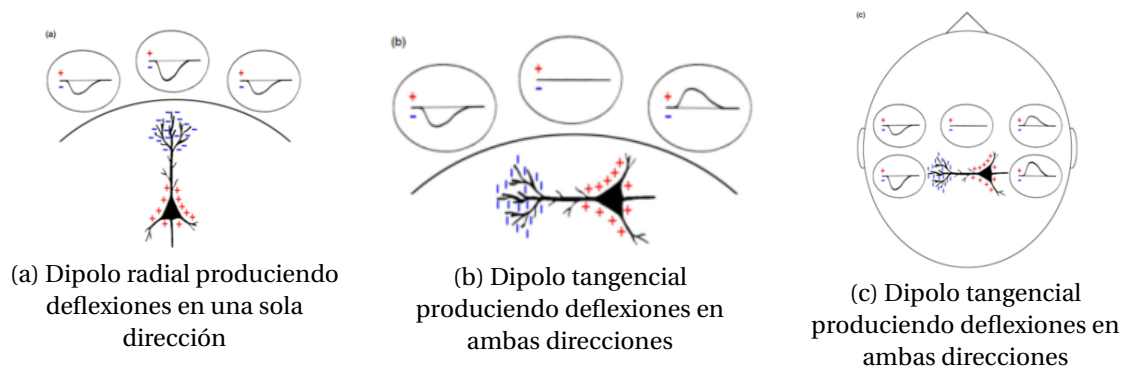


Figura 1.1: Medición de dipolos radiales y tangenciales. Fuente: (Jackson & Bolger, 2014).

Debido a la naturaleza una sola neurona es demasiado pequeña para ser medido desde el cuero cabelludo. Sin embargo, dado que los electrodos detectan una suma de cargas en su entorno, los dipolos de múltiples neuronas en una región se suman entre en sí. La suma de varios dipolos individuales en un área es medible como un único dipolo, cuya magnitud refleja el número de neuronas cuyos dipolos se están sumando. Sin embargo, debido a que los electrodos medirán la suma de ambos extremos tanto positivos como negativos. De los dipolos en el cerebro, para producir una señal medible (no nula), las neuronas deben estar dispuestas como se muestra en la figura 1.2 (a) y activas de forma sincrónica como se muestra en la figura 1.2 (b). La disposición de las neuronas es necesaria para producir un dipolo medible, ya que, si las neuronas están alineadas en la misma orientación, sus señales pueden sumarse para formar una señal más grande. En cualquiera otra configuración, los extremos positivo y negativo de los dipolos individuales se cancelarán entre sí. La sincronización de la actividad es necesaria para generar una carga neta en el lado del dipolo orientado hacia el cuero, en lugar de que las cargas se cancelen entre sí, y una señal lo suficientemente grande

como para poder ser medida [11].




Figura 1.2: Disposición paralela y la actividad sincrónica que permite que la señal sea medida en el cuero cabelludo. Fuente: (Jackson & Bolger, 2014). a: Las señales negativas se sumaran y serán medibles en el cuero cabelludo. b: Las señales positivas y negativas se cancelaran entre sí en el cuero cabelludo, por lo tanto no serán medibles. c: No surge un dipolo claro de la disposición aleatoria de las cargas positivas y negativas, por lo que no se medirá ninguna señal en el cuero cabelludo.

1.2.2. ¿Cómo el EEG viaja desde el cerebro hasta el dispositivo de registro?

En las siguientes secciones se discuten cómo es el proceso de registro de las señales EEG el cual se abordan mediante dos etapas. La primera etapa se discute lo que sucede dentro del cerebro y la segunda como estas señales viajan del cerebro al electrodo para su registro.

1.2.2.1. Dentro del cerebro

La conducción de volumen es responsable de la propagación de la señal EEG dentro del cerebro. La conducción de volumen es el proceso mediante el cual un grupo

de iones repele a los iones cercanos que no tienen la misma carga. Estos iones repelidos, a su vez, repelen a otros iones con la misma carga, lo que resulta en una onda de carga que viaja a través del espacio extracelular. En el caso de un volumen homogéneo, esta onda de iones cargados puede propagarse a través del volumen sin impedimentos. Si las corrientes pudieran viajar sin obstáculos a través de la corteza, el resultado sería una cascada de potenciales de acción disparándose sin especificidad. Es por ello que el cerebro produciría eventos de convulsión constantes. Sin embargo, el cerebro no es un volumen homogéneo. Los iones no pueden viajar a través de los tractos nerviosos recubiertos de mielina ni otros obstáculos físicos. Diferentes densidades de tejidos pueden impedir o permitir el flujo de iones, según sus propiedades eléctricas inherentes y su disposición física. Además, los dipolos no son todos del mismo tamaño, una señal proveniente de un dipolo grande puede viajar mucho más lejos que una señal de un dipolo pequeño [11].

1.2.2.2. Del cerebro al electrodo

Para ser medida la señal EEG con electrodo fuera de la cabeza, la señal eléctrica creada por la actividad neuronal debe viajar desde el cerebro, a través de las capas duramadre, el cráneo, el cuero cabelludo y finalmente hasta el electrodo. Una vez que la señal conducida por volumen alcanza el borde del volumen a través del cual viaja, la conducción por volumen ya no puede ocurrir, ya que los iones no pueden salir de dicho volumen. Entre los volúmenes, una forma de capacitancia se vuelve responsable de la propagación de la señal tal como se muestra en la figura 1.3. Debido a que el gel es un conductor, la señal llega al electrodo con menos atenuación de la que ocurriría si el gel no estuviera presente. Un capacitor en su forma más general consiste en dos grupos de cargas separadas por una capa aislante (un dieléctrico). La capa aislante evita que los iones se mezclen, si no estuviera la capa aislante, entonces puede acumularse una diferencia de carga a través de la capa, donde los iones negativos se empujan contra un lado de la membrana y los iones positivos se acumulan en el otro lado. La cantidad de carga que se acumula en el otro lado está determinada por las propiedades de los materiales aislantes entre los grupos de cargas, el tamaño del grupo cargado, y la distancia entre la carga y la capa aislante. La secuencia de capas desde el cerebro hasta

las capas de la duramadre, las capas del cráneo, las capas del cuero cabelludo, el gel del electrodo y electrodo forman una serie de volúmenes conductores separados por capas aislantes, similar a una pila de capacitores [11].




Figura 1.3: La pila de capacitadores con del de electrodo, mostrando la propagación de la señal neuronal a través de las capas del cerebro, duramadre, caneo y gel del electrodo hasta llegar al electrodo. Fuente: (Jackson & Bolger, 2014).

1.2.3. Redes neuronales artificiales

Las redes neuronales artificiales (ANN) se han convertido en modelos populares para resolver distintos problemas de aplicación de diferentes tareas como clasificación, agrupamiento, reconocimiento de patrones y predicción [14], [15], [16]. Las ANNs constituyen una técnica de aprendizaje automático que ha mostrado un desempeño competitivo frente a modelos estadísticos y de regresión. Una ANN (ver Figura 1.4) está formada por una capa de entrada, una o más capas ocultas y una capa de salida. Estas capas se conectan de manera secuencial, y cada una de ellas está integrada por n neuronas. La capa de entrada puede representarse matemáticamente como un vector. En cada neurona, el vector de entradas corresponde a las señales de entrada, mientras que el vector de pesos determina la influencia de cada entrada sobre la salida. La operación de producto punto entre estos vectores constituye la etapa de combinación lineal. Posteriormente, se aplica una función de agregación que tiene como propósito

integrar las señales ponderadas. El resultado de esta función es procesado por una función de activación, la cual determina el nivel de activación de la neurona. Esta función también permite limitar el rango de salida y dotar al modelo de capacidad de representación no lineal, al aplicar un mapeo no lineal sobre el valor obtenido por la función de agregación [14].

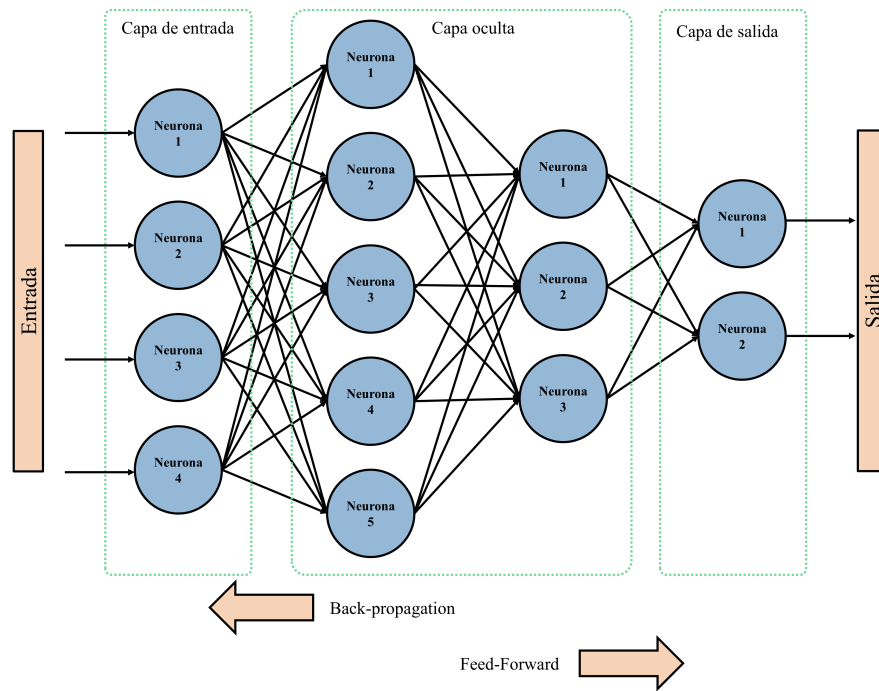


Figura 1.4: Arquitectura de red neuronal artificial

1.2.4. Adaptación de dominio en redes neuronales artificiales

La adaptación de dominio es una técnica en aprendizaje automático. El objetivo de aplicar dicha técnica es para reducir las diferencias de distribución entre distintos conjuntos de datos [17]. En el área biomédica esta técnica es fundamental ya que existen distintos conjuntos de datos médicos. Por lo que un método adecuado de adaptación de dominio puede aumentar significativamente la potencia de obtener el mismo rendimiento de modelos de aprendizaje en los diferentes sitios o centros.

Por ejemplo, de acuerdo a lo expuesto por los investigadores Courty et al., [18], Lin et al., [19] y Wilson et al., [20] en el contexto de aprendizaje supervisado se parte de la premisa de que los datos prueba son una realización del mismo proceso que gene-

ró el conjunto de entrenamiento. El problema surge cuando en aplicaciones prácticas esto no se cumple, lo que afecta el rendimiento del modelo ligeramente.

Entonces las estrategias de adaptación de dominio pueden ser semisupervisada o no supervisada [21], [18].

- Adaptación de dominio semisupervisada: se buscan proyecciones que sean discriminativas en ambos dominios (muestras de origen y muestras transformadas del dominio objetivo) [18, 21].
- Adaptación de dominio no supervisada: parte del supuesto de que no existen etiquetas en el dominio objetivo. Como la representación (espacio latente) se comparte entre dominios, las muestras etiquetadas proyectadas del origen pueden usarse para entrenar un modelo general [18, 21].

Una definición formal de adaptación de dominio [22] es sea un dominio fuente D_s , compuesto por un espacio de características χ_s y una distribución marginal de probabilidad $P(X_s)$, tal que:

$$D_s = \{\chi_s, P(X_s)\}$$

Existe un conjunto de muestras $X_s = \{x_{s1}, x_{s2}, \dots, x_{sn}\}$ y sus correspondientes etiquetas $Y_s = \{y_{s1}, y_{s2}, \dots, y_{sn}\}$ provenientes del espacio de etiquetas Υ . De manera análoga, el dominio destino D_t está compuesto por un espacio de características χ_t y una distribución marginal $P(X_t)$, de forma que:

$$D_t = \{\chi_t, P(X_t)\}$$

El conjunto de muestras del dominio destino es $X_t = \{x_{t1}, x_{t2}, \dots, x_{tn}\}$, con sus etiquetas correspondientes $Y_t = \{y_{t1}, y_{t2}, \dots, y_{tn}\}$, también del espacio Υ . En muchos escenarios, las etiquetas del dominio destino no están disponibles, sólo algunas están disponibles, o incluso no hay datos. La tarea en el dominio fuente se define como:

$$T_s = \{Y_s, P(Y_s | X_s)\}$$

Y en el dominio destino como:

$$T_t = \{Y_t, P(Y_t | X_t)\}$$

Si existe un modelo matemático $f : X_s \rightarrow Y_s$ y las tareas T_s y T_t están relacionadas, y si el mismo modelo f es capaz de mapear $X_t \rightarrow Y_t$ con un error mínimo o aceptable, entonces se dice que el modelo f se ha adaptado correctamente al dominio destino D_t desde el dominio fuente D_s .

1.2.5. EEG con artefactos y conjunto de datos

Para la presente investigación, y de acuerdo con lo reportado en el estado del arte, existen tres conjuntos de datos comúnmente utilizados que permiten establecer un consenso y realizar comparaciones entre las distintas propuestas de investigación. A continuación se describe que es un artefacto y los conjuntos de datos de acuerdo a lo reportado por los autores.

1.2.5.1. Artefactos y sus tipos


Un artefacto es una señal no deseada presente en la señal EEG que no es de origen cerebral. En la figura 1.5 se pueden observar distintos tipos de artefactos, tanto fisiológicos como no fisiológicos. Según lo expuesto por Bitbrain [23] y Quintero-Rincón et al. [24], si la fuente del artefacto proviene del cuerpo del sujeto, se clasifica como artefacto fisiológico, mientras que si la fuente es externa, se considera un artefacto no fisiológico. En la figura 1.5 (a) se muestra una señal EEG limpia. Dependiendo del tipo de artefacto presente, esta puede presentar alteraciones en su amplitud y/o frecuencia. Por ejemplo, en la figura 1.5 (d) se presenta un artefacto de movimiento ocular, el cual genera cambios de alta amplitud en la señal EEG. Otro tipo de artefacto fisiológico es el producido por el movimiento muscular, representado en la figura 1.5 (e), que

se caracteriza por una alta frecuencia. Dentro de los artefactos musculares también se incluyen los generados por acciones como masticar, mostrados en la figura 1.5 (b), y el mareo, ilustrado en la figura 1.5 (f). Por otro lado, en la figura 1.5 (c) se representa un artefacto no fisiológico causado por un estallido de electrodo.


Además de los artefactos mostrados en la figura, existen otros como los generados por la actividad eléctrica del corazón. Aunque estos suelen tener una amplitud baja en el EEG, en ocasiones dependiendo de la ubicación del electrodo del participante pueden generar una distorsión rítmica observable en la señal. Algunos artefactos no fisiológicos adicionales incluyen el mal contacto del electrodo, que genera artefactos de baja frecuencia, transitorios y limitados a un solo canal. También se encuentran los problemas con el canal de referencia, ya sea por una colocación incorrecta, que provocan cambios abruptos de alta amplitud en todos los canales, estos tienden a estabilizarse gradualmente una vez que la referencia se ha colocado correctamente. Finalmente, puede presentarse interferencia eléctrica externa, que se manifiesta como una señal de alta amplitud, generalmente localizada en un solo canal. Esta interferencia suele originarse por la proximidad a fuentes de corriente alterna.

1.2.5.2. Corpus de señales EEG simulado


De acuerdo con Cohen et al. [25], los datos simulados resultan ser una herramienta valiosa por varias razones. En primer lugar, permiten validar métodos de análisis utilizando datos de referencia. Además, ayudan a identificar tanto las ventajas como las limitaciones de dichos métodos, así como a comprender mejor su funcionamiento. Asimismo, los datos simulados contribuyen a una comprensión más profunda de los datos reales a analizar y fomentan una reflexión más crítica y cuidadosa sobre los mismos. Finalmente, su uso puede mejorar las habilidades de razonamiento necesarias para decidir qué tipo de análisis aplicar y cómo interpretar los resultados. El algoritmo para generar una señal de EEG sintética se muestra en el algoritmo 1. Primero se define una función gaussiana $f(t)$, la cual representa una envolvente temporal centrada en μ y con desviación estándar σ . Posteriormente, se genera una señal senoidal $x(t)$ con frecuencia f y una fase aleatoria ϕ distribuida uniformemente. Luego, se calculan las




a) Señal base EEG




b) Artefacto de Masticación




c) Artefacto Electrodo Pop



d) Artefacto de Movimiento Ocular



e) Artefacto Muscular



f) Artefacto de Mareo

Figura 1.5: Ejemplos de señal EEG y EEG con varios tipos de artefactos.

amplitudes a_k aplicando un factor de decaimiento exponencial controlado por el parámetro ed , donde τ_k es un valor aleatorio uniforme. Con estas amplitudes y un vector de fases aleatorias Φ , se construye una representación en frecuencia fc utilizando la forma compleja $a_k \cdot e^{j\Phi}$. Se aplica la Transformada Inversa de Fourier a esta representación, obteniendo la señal $g(t)$ como el doble de la parte real del resultado. Finalmente, la señal EEG sintética se construye combinando la envolvente $f(t)$, la señal senoidal $x(t)$ y el ruido $g(t)$ mediante la expresión $EEG(t) = f(t) \cdot x(t) + g(t)$.

Algoritmo 1: Generación de señal sintética EEG con componentes sinusoidales, envolvente gaussiana y ruido

Entrada: Parámetros μ, σ, f, ed

$$f(t) = e^{-\frac{(t-\mu)^2}{2\sigma^2}}$$

$$x(t) = \sin(2\pi f t + \phi)$$

$$a_k = \tau_k \cdot e^{-\frac{k}{ed}}$$

$$fc = a_k \cdot e^{j\Phi}$$

$$g(t) = 2 \cdot \text{Re}(\mathcal{F}^{-1}(fc))$$

$$EEG(t) = f(t) \cdot x(t) + g(t)$$

Es común que al generar una señal EEG sintética, también se desee proyectar actividad dipolar sobre la misma. Para ello, se realiza una selección de fuentes dipolares en el cuero cabelludo, como se muestra en la figura ?? (a). Posteriormente, mediante el algoritmo descrito en el Algoritmo 1 y la multiplicación por la matriz de ganancia ilustrada en la figura ?? (b), se obtiene una señal EEG que muestra actividad dipolar en la zona seleccionada de la figura ?? (a).

1.2.5.3. Corpus EGGdenoiseNet semisintético

El corpus de datos Benchmark EGGdenoiseNet de Huang et al., [26] es un conjunto de datos adecuado para la investigación de eliminación de ruido en señales EEG basado en redes de aprendizaje profundo. Este conjunto de datos se creó a partir de repositorios públicos en estudios previos, los cuales proveen datos de EEG, EOG y EMG. Para generar EEG limpio, EOG puro y EMG puro, primero se preprocesaron los datos y luego se segmentaron en segmentos de 2 segundos. Posteriormente, se reescalaron los segmentos para que tuvieran la misma varianza. Finalmente, cada segmento fue

revisado visualmente por un experto para asegurar que estuvieran limpios y fueran utilizables. El conjunto de datos incluyó a 52 participantes que realizaron tanto tareas de movimiento real como imaginario de la mano izquierda y derecha, con EEG de 64 canales grabados simultáneamente a una frecuencia de muestreo de 512 Hz. Para ambas tareas (real e imaginaria), un participante repitió un segmento de 2 segundos de línea base y 3 segundos de movimiento, con intervalos aleatorios de 4.1 a 4.8 segundos durante 20 minutos. Los datos fueron filtrados pasa banda entre 1 y 80 Hz, con un filtro notch a la frecuencia de la línea eléctrica, y luego se remuestro a 256 Hz. Para obtener el EEG limpio como referencia, las señales EEG de 64 canales fueron procesadas con ICLabel, una herramienta para eliminar artefactos en EEG mediante composición de componentes independientes (ICA). Luego, las señales EEG puras fueron segmentadas en segmentos unidimensionales de 2 segundos. Cabe destacar que, para garantizar la universalidad de este conjunto de datos, no se construyeron señales de EEG limpias con un número específico de canales debido a la diversidad de EEG, sino que se construyó un conjunto de datos con señales EEG de un solo canal. El conjunto de datos tiene un total de 4514 segmentos de EEG, 3400 segmentos con artefactos oculares y 5598 segmentos con artefactos miogénicos. Entonces, para generar el EEG semisintético se aplicó el algoritmo 2. El algoritmo inicia calculando la potencia de la señal EEG $s(n)$, donde esta primer potencia obtenida se convierte a una escala logarítmica para obtener la potencia de la señal EEG en dB. Posteriormente se calcula ahora la potencia del artefacto con diferentes escalas de Relación Señal-Ruido (SNR), ahora la señal correspondiente al artefacto se le aplica una normalización y escalamiento. Finalmente, la señal con artefactos es la suma de la señal EEG $s(n)$ más el resultado de la última ecuación aplicada en el algoritmo 2.

1.2.5.4. Corpus TUH EEG reales

El corpus TUH EEG Artifact Corpus de EEG del Hospital de la Universidad de Temple (TUEG) de Obeid & Picone [27] fue desarrollado para apoyar investigaciones de vanguardia en la interpretación automática de EEG utilizando aprendizaje automático este tiene un total de 328 pacientes. El corpus consta de datos de señales EEG y de informes de EEG escritos por el neurólogo a cargo para cada sesión del paciente.

Algoritmo 2: Agregado sintético de artefactos a la señal EEG

Entrada: $s(n)$: Señal original de EEG

$v(n)$: Señal de artefacto

SNR : Relación señal-ruido deseada (dB)

$$P_{EEG} \leftarrow \frac{1}{N} \sum_{n=1}^N s(n)^2$$

$$P_{EEG}^{dB} \leftarrow 10 \cdot \log_{10}(P_{EEG})$$

$$P_{artefacto} \leftarrow \frac{P_{EEG}}{10^{SNR/10}}$$

$$Artefacto(n) \leftarrow \sqrt{P_{artefacto}} \cdot \frac{v(n)}{\sigma(v(n))}$$

$$EEG_{conArtefacto}(n) \leftarrow s(n) + Artefacto(n)$$

Este corpus consiste completamente en datos clínicos recolectados desde 2002 hasta 2019 en el Hospital de la Universidad de Temple (TUH). Los datos de señales EEG se recopilieron utilizando diversas generaciones de equipos EEG. La mayoría de los datos de 2002 a 2019 se recopilieron utilizando el equipo de grabación NicoletOne de Natus Medical Incorporated. Los datos en TUEG se recopilieron en diversas ubicaciones del hospital, incluyendo la unidad de cuidados intensivos, la unidad de monitoreo de epilepsia, la sala de emergencias y los servicios ambulatorios. Las anotaciones consisten en tipos básicos de eventos que tienen los siguientes artefactos: movimiento ocular, masticación, escalofríos, artefactos musculares y una categoría general utilizada cuando ocurre cualquiera de los tres tipos de artefactos: salto de electrodo, artefacto electrostático y artefacto de conductor. En la tabla 1.1 se muestra la cantidad de artefactos totales que hay por cada clase.

Cuadro 1.1: Cantidad de artefactos por tipo del Corpus TUH EEG

Tipo de artefacto	Cantidad
musc	51,052
eyem	38,569
elec	33,130
eyem_musc	18,677
musc_elec	7,651
chew	6,482
eyem_elec	2,422
eyem_chew	864
shiv	613
chew_musc	243
elpp	172
chew_elec	152
eyem_shiv	45
shiv_elec	1
TOTAL	160,073

1.2.6. Extracción de características en EEG

Una de las tareas fundamentales al entrenar un modelo de aprendizaje profundo es la obtención de características representativas. En esta investigación se optó por utilizar la transformada de Fourier de tiempo corto (STFT) tanto para tareas de clasificación como para regresión. Según Maiwald et al. [28], este tipo de características ha demostrado presentar un menor sesgo en el rendimiento de los modelos de aprendizaje. Además, en el caso de un modelo de regresión, es posible recuperar la señal aplicando la transformada inversa, según lo propuesto por Lin et al. [19], lo que permite obtener nuevamente la señal reconstruida para su posterior análisis. Entonces de acuerdo con la definición proporcionada por Goyal & Pabla [29], la Transformada de Fourier de Tiempo Corto (STFT) se introdujo para superar las limitaciones de la Trans-

formada Rápida de Fourier (FFT). Normalmente, se utiliza para la extracción de contenido de frecuencia de banda estrecha en señales no estacionarias o ruidosas. La idea básica de la STFT es dividir la señal inicial en pequeñas ventanas de tiempo y aplicar la Transformada de Fourier a cada segmento de tiempo para expresar la variación en el contenido de frecuencia de la señal a lo largo del tiempo en ese segmento, tal como se muestra en la figura 1.6.




Figura 1.6: Transformada de Fourier en Tiempo Corto

La STFT ofrece un análisis con ancho de banda absoluto constante para identificar componentes armónicos y proporciona una resolución constante en la representación bidimensional, independientemente de la frecuencia real. La ecuación matemática para la Transformada de Fourier de Tiempo Corto se expresa como:

$$S(f, \tau) = \sum_{\tau=0}^{N-1} x(t) \omega(t - \tau) e^{-j2\pi f \tau} \quad (2.3)$$

donde $x(t)$ es la señal que se está analizando y $\omega(t)$ es la función ventana centrada en el tiempo τ . Actualmente, el espectrograma de Fourier (es decir, la amplitud al cuadrado, $|S(f, \tau)|^2$) se muestra en un diagrama de tiempo-frecuencia. Lamentablemente, la ventana fija utilizada en la STFT implica una resolución fija tanto en el dominio del tiempo como en el dominio de la frecuencia. El problema radica en que la

precisión para obtener información de frecuencia está limitada por la longitud de la ventana en comparación con la duración de la señal de interés. La STFT tiene la limitación de baja resolución. Este problema surge al elegir una ventana pequeña, lo que no permite capturar adecuadamente el comportamiento transitorio dinámico de la estructura. El tamaño de la ventana determina la precisión temporal: cuanto mayor es la ventana, peor es la resolución temporal pero mejor la resolución en frecuencia, y viceversa. Además, la STFT no permite observar frecuencias naturales cercanas entre sí.

Ahora para obtener la inversa de la Transformada de Fourier de Tiempo Corto (STFT), utilizamos la misma ventana y el mismo proceso de segmentación que en la STFT directa. La idea es reconstruir la señal original $x(t)$ a partir de la representación tiempo-frecuencia $S(f, \tau)$. Para recuperar $x(t)$ a partir de $S(f, \tau)$, se aplica la IDFT para obtener $s(\tau, t)$, que corresponde al segmento de señal en la ventana τ :

$$s(\tau, t) = \text{IDFT}\{S(f, \tau)\} \quad (2.4)$$

Posteriormente, se multiplica $S(f, \tau)$ por la misma ventana utilizada en la STFT directa, desplazada por el centro de la ventana τ :

$$s(\tau, t) \cdot \omega(t - \tau) \quad (2.5)$$

Finalmente, mediante la suma de los bloques solapados, se obtiene la señal reconstruida $y(t)$:

$$y(t) = \sum_{\tau} s(\tau, t) \cdot \omega(t - \tau) \quad (2.6)$$

La reconstrucción será exacta ($y(t) = x(t)$) solo si se elige adecuadamente la función ventana $\omega(t)$. Si la ventana no se selecciona correctamente, la señal reconstruida $y(t)$ no coincidirá con la señal original $x(t)$. El uso de una ventana inapropiada puede resultar en errores de reconstrucción, ya que afecta la precisión tanto en el do-

minio del tiempo como en el dominio de la frecuencia.

1.2.7. Métricas de evaluación

Para medir el rendimiento de una red neuronal artificial, dependiendo de la tarea que se esté llevando a cabo, ya sea de clasificación y/o regresión, existen diversas métricas que permiten evaluar su desempeño. Estas métricas proporcionan información sobre el comportamiento de rendimiento del modelo de aprendizaje y pueden indicar si está presentando una buena o mala generalización de los datos.

1.2.7.1. Métricas de evaluación para tareas de clasificación

Para evaluar el rendimiento de un modelo en una tarea de clasificación, la cual predice categorías o clases, se utilizan las métricas mencionadas por Grandini et al. [30], Tohka et al. [31] y Géron [32].

Tasas de error simples La forma de evaluar el rendimiento es calculando el número de errores correctas realizadas sobre un conjunto de datos determinado. Si el número de errores es elevado, el rendimiento no es bueno. La exactitud puede definirse como una razón simple:

$$\text{exactitud} = \frac{\text{número de clasificaciones correctas}}{\text{número total de muestras a clasificar}} \quad (1.1)$$

Sensibilidad Es el número de instancias de la clase positiva que fueron clasificadas correctamente, dividido entre el número total de instancias de la clase positiva.

$$\text{Sensibilidad} = \frac{TP}{TP + FN} \quad (1.2)$$

Esta métrica cuantifica qué tan bien el clasificador detecta los casos de la clase positiva. Una sensibilidad baja implica que muchas instancias positivas no son detectadas.

Precisión Es el número de instancias que realmente pertenecen a una clase X dividido entre el número de instancias que el clasificador predice como pertenecientes a la clase X .

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (1.3)$$

Sensibilidad o Recall Es el número de casos de la clase X que fueron correctamente clasificados como clase X , dividido entre el número total de casos reales de la clase X :

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.4)$$

F1-score Es la media armónica entre la precisión y el recall:

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (1.5)$$

Si la precisión o el recall tienen valores bajos, el valor del F1-score será bajo. Por ello, el F1-score es una métrica más sensible que la exactitud para evaluar el desempeño de un modelo en presencia de clases desbalanceadas.

Matriz de confusión La matriz de confusión permite cuantificar el rendimiento de un clasificador sobre diferentes clases. Las filas de la matriz contienen las etiquetas verdaderas y las columnas los resultados de la clasificación. El elemento de la matriz (i, j) representa el número de casos que en realidad pertenecen a la clase i , pero que fueron clasificados como pertenecientes a la clase j .

1.2.7.2. Métricas de evaluación para tareas de regresión

Para evaluar el rendimiento de un modelo de regresión, el cual predice valores numéricos continuos, se utilizan las métricas mencionadas por Botchkarev et al. [33] y Lopes et al. [34].

Error Cuadrático Medio (MSE) En el dominio temporal, el Error Cuadrático Medio (MSE) se utiliza para evaluar el rendimiento de un algoritmo, calculando las diferencias entre la señal EEG verdadera $EEG_{entrada}(i) \in \mathbb{R}^{1 \times N}$ y la señal EEG corregida $EEG_{salida}(i) \in \mathbb{R}^{1 \times N}$. El MSE se calcula como:

$$MSE = \frac{1}{N} \sum_{i=1}^N (EEG_{entrada}(i) - EEG_{salida}(i))^2 \quad (1.6)$$

donde:

- N : número total de muestras.
- $EEG_{entrada}(i)$: valor de la señal verdadera en el índice i .
- $EEG_{salida}(i)$: valor de la señal corregida en el índice i .

Error Cuadrático Medio de la Raíz (RMSE) El RMSE proporciona una medida de la magnitud de los errores entre la señal estimada y la verdadera:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (EEG_{entrada}(i) - EEG_{salida}(i))^2} \quad (1.7)$$

Error Cuadrático Medio Normalizado (NMSE) El NMSE proporciona una medida relativa del error, normalizada por la energía de la señal verdadera:

$$NMSE = \frac{\sum_{i=1}^N (EEG_{salida}(i) - EEG_{entrada}(i))^2}{\sum_{i=1}^N (EEG_{entrada}(i))^2} \quad (1.8)$$

Error Relativo (RE) El RE proporciona una medida de la discrepancia entre la señal corregida y la verdadera:

$$RE = \frac{\|EEG_{salida} - EEG_{entrada}\|}{\|EEG_{entrada}\|} \quad (1.9)$$

Relación Señal a Artefacto (SAR) Para señales EEG contaminadas $EEG_{con}(i) \in \mathbb{R}^{1 \times N}$, la relación señal a artefacto antes de la corrección es:

$$SAR_B = \frac{\frac{1}{N} \sum_{n=1}^N |EEG_{entrada}(n)|^2}{\frac{1}{N} \sum_{n=1}^N |EEG_{con}(n) - EEG_{entrada}(n)|^2} \quad (1.10)$$

Después de la corrección, se calcula como:

$$SAR_A = \frac{\frac{1}{N} \sum_{n=1}^N |EEG_{entrada}(n)|^2}{\frac{1}{N} \sum_{n=1}^N |EEG_{salida}(n) - EEG_{entrada}(n)|^2} \quad (1.11)$$

La ganancia en la relación señal a artefacto se expresa como:

$$\gamma = 10 \log_{10} \left(\frac{SAR_A}{SAR_B} \right) \quad (1.12)$$

Información Mutua (MI) La información mutua entre el EEG corregido y el verdadero se calcula como:

$$MI = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(a, b) \log \left(\frac{f(a, b)}{f(a)f(b)} \right) da db \quad (1.13)$$

donde $f(a, b)$ es la densidad conjunta y $f(a)$, $f(b)$ las marginales.

Error Absoluto Medio (MAE) En el dominio frecuencial, el MAE mide la distorsión entre densidades espectrales de potencia:

$$MAE = |P_{entrada}^{EEG} - P_{salida}^{EEG}| \quad (1.14)$$

Coficiente de Correlación de Pearson (PCC) El PCC mide la correlación lineal entre la señal corregida y la señal verdadera:

$$PCC(x, y) = \frac{Cov(x, y)}{\sigma_x \sigma_y} \quad (1.15)$$

donde σ_x y σ_y son las desviaciones estándar de x e y , respectivamente.

1.2.7.3. Métricas de evaluación para tareas de adaptación de dominio en redes neuronales artificiales

En el contexto del aprendizaje de redes neuronales artificiales, existe el término funciones de pérdida, las cuales se utilizan para evaluar el desempeño de los modelos. Cada una de estas funciones es adecuada para distintos tipos de tareas. Para nuestra propuesta de investigación, se emplearán la entropía cruzada y el error cuadrático medio en el dominio fuente. Para llevar a cabo la adaptación al dominio objetivo, se usará Sinkhorn, cuyas funciones de pérdida adicionales para monitorear durante el entrenamiento de la red neuronal artificial incluirán la divergencia de Kullback-Leibler y la de Jensen-Shannon.

Entropía Cruzada La entropía cruzada es una función de pérdida ampliamente utilizada en tareas de clasificación y es una de las más comunes en el aprendizaje automático. Coincide con la pérdida logística aplicada a las salidas de una red neuronal cuando se utiliza la función softmax. Este problema supervisado consiste en asignar cada entrada a una de un número finito de categorías discretas [35].

$$\text{Entropía cruzada} = - \sum_{i=1}^N y_i \cdot \log(p_i) \quad (1.16)$$

Donde:

- y_i : Etiqueta esperada para la muestra i .
- p_i : Probabilidad predicha de que la muestra pertenezca a la clase i .
- N : Total de clases.

Error Cuadrático Medio El objetivo de esta medida es comparar dos conjuntos de datos mediante un valor cuantitativo que indique el grado de similitud o, inversamente, el nivel de error o desviación entre ellos. Generalmente, se asume que uno de los conjuntos representa una referencia, mientras que el otro representa una predicción o una versión perturbada [36]. El Error Cuadrático Medio se define como:

$$\text{MSE}(\mathbf{x}, \mathbf{y}) = \frac{1}{N} \sum_{i=1}^N (x_i - y_i)^2 \quad (1.17)$$

En esta definición, es común referirse al error $e_i = x_i - y_i$, que representa la diferencia entre el valor esperado y el valor obtenido para el elemento i .

Divergencia Kullback-Leibler La divergencia de Kullback-Leibler (KL) [37] es una medida que cuantifica cuán cercana está una distribución de probabilidad $p = \{p_i\}$ a una distribución modelo $q = \{q_i\}$. Se define como:

$$D_{KL}(p \parallel q) = \sum_i p_i \log_2 \left(\frac{p_i}{q_i} \right) \quad (1.18)$$

Esta medida analiza la probabilidad de observar ciertos datos si asumimos que un modelo q es correcto. Es decir, la divergencia KL no solo mide una distancia entre distribuciones, sino que también cuantifica qué tan bien un modelo q explica los datos generados por una distribución real p .

Distancias y Divergencia Jensen-Shannon La divergencia de Jensen-Shannon (JSD) es una versión suavizada y simetrizada de la divergencia de Kullback-Leibler, que mide la diferencia entre dos distribuciones de probabilidad P y Q [38], [39]. Se define como:

$$\text{JSD}(P \parallel Q) = \frac{1}{2} D(P \parallel M) + \frac{1}{2} D(Q \parallel M) \quad (1.19)$$

donde $M = \frac{1}{2}(P + Q)$ y $D(\cdot \parallel \cdot)$ representa la divergencia de Kullback-Leibler.

Pérdida Sinkhorn Para calcular la divergencia de Sinkhorn S_ϵ , se requieren dos pares (α, \mathbf{x}) y (β, \mathbf{y}) , donde α y β son medidas de probabilidad discretas, y \mathbf{x} y \mathbf{y} son los puntos soporte correspondientes [1]. El cálculo implica obtener los vectores duales (f, g) y (p, q) , asociados respectivamente a las medidas cruzadas y autocorrelacionadas. Estos vectores se calculan mediante iteraciones de Sinkhorn, incluyendo su versión simétrica. La divergencia de Sinkhorn se define como:

$$S_{\varepsilon}(\alpha, \mathbf{x}, \beta, \mathbf{y}) = \sum_{i=1}^N \alpha_i (f_i - p_i) + \sum_{j=1}^M \beta_j (g_j - q_j) \quad (1.20)$$

Respecto a los gradientes, es importante considerar que el algoritmo de Sinkhorn sigue una estructura de punto fijo. Esto permite derivar de manera más eficiente con respecto a las medidas o parámetros, en comparación con métodos de diferenciación automática que tratan cada iteración como una operación independiente.

1.3. Estado del arte

Al revisar la literatura, se observó que han surgido diversas técnicas orientadas a la identificación y eliminación de artefactos en señales EEG, mediante la aplicación de métodos de aprendizaje automático, tanto en modelos de clasificación como en modelos de regresión. En esta sección se analizarán las diferentes propuestas de investigación relacionadas con dichos enfoques.

Para abarcar la perspectiva de identificación de artefactos, como primer trabajo relacionado con nuestra propuesta de investigación, tenemos que los autores Peh et al., [40] propusieron el desarrollo de una red neuronal convolucional usando transformadores, utilizando la pérdida de coincidencia de creencias. La implementación consistió en cinco detectores individuales de canales y por segmento, obteniendo una detección automatizada de cinco tipos de artefactos como: masticación (CHEW), estallido de electrodo (ELPP), movimiento ocular (EOG), movimiento muscular (EMG) y escalofríos (SHIV). El conjunto de datos utilizado por este trabajo fue el Corpus TUH EEG [27], y las características para el entrenamiento del modelo fueron características estadísticas. El trabajo mencionó que los principales resultados que obtuvieron mediante la métrica de precisión balanceada (BAC) fueron de 0.947, 0.735, 0.826, 0.857 y 0.655, respectivamente. En este mismo sentido, los autores Kim & Keene [41] propusieron un modelo basado en aprendizaje profundo, el cual se basa en una red de memoria a corto-largo plazo (LSTM) y una red neuronal convolucional (CNN) para clasificar el tipo de artefacto. Ellos emplearon el conjunto de datos Corpus TUH EEG [27], y las características para entrenar el modelo consistieron en segmentos de 1 segundo de la

señal EEG. El modelo logró una precisión de clasificación de cinco clases del 67.59%, y una tasa verdadera positiva del 80 % con un 25.82 % de falsas alarmas para la clasificación binaria de artefactos. Finalmente, mencionan que, dado que el modelo contiene 65 MB de parámetros, permitiendo su implementación en dispositivos portátiles como Raspberry Pi, dando como resultado inferencias en tiempo real. Ahora, de manera similar, el trabajo de Maiwald et al., [28] lleva a cabo una representación alternativa de datos de señales EEG para la clasificación de artefactos dentro de señales EEG, donde las señales fueron convertidas en imágenes de series temporales. Se usaron técnicas de visualización como gramian, recurrencia, transformada wavelet continua, espectrograma, correlograma y cadenas de Markov. El conjunto de datos utilizado para esta investigación fue el Corpus TUH EEG [27]. Los modelos con mejor rendimiento de clasificación fueron Xception y EfficientNetB0 con características de Markov, pero las características que presentaron un sesgo moderado fueron los espectrogramas, mostrando un F1-Score de 90.5 % y 89.4 %, y una precisión de 89 % y 89.9 %, respectivamente. Con un enfoque comparable, desde la perspectiva de clasificación se tiene el modelo propuesto por Bahador et al., [42], donde proponen el uso de una CNN. Ellos proponen mapear señales desde un espacio multicanal a un espacio RGB bidimensional, en el cual se tiene en cuenta simultáneamente la correlación de todos los canales de EEG. El conjunto de datos usado para este estudio fue uno proporcionado por la UCI del Hospital Universitario de Oulu. Las características usadas para alimentar al modelo fueron datos de coeficientes de correlación. Los resultados que obtuvieron fueron de 92.30 % (AUC=0.96) para diferentes tipos de artefactos, además de mostrar una inferencia del modelo de 0.0181 segundos para la toma de decisiones en tiempo real. Finalmente, Saba-Sadiya et al., [4] propusieron un modelo de detección y corrección no supervisada de artefactos. El modelo empleado consistió de un codificador-decodificador. Para el entrenamiento del modelo se extrajeron 58 características, tales como la entropía de Shannon, la entropía de las señales de onda descompuesta y la entropía de Tsallis. Además, se incluyeron características de continuidad, que capturan la regularidad y volatilidad de la actividad EEG, como explosiones, picos y variaciones en la media y desviación estándar en los dominios de frecuencia y potencia. Se consideraron características de conectividad, que reflejan la dependencia estadística en-

tre canales del EEG y permiten describir redes funcionales clave en el funcionamiento normal del cerebro. El modelo propuesto superó ampliamente al clasificador aleatorio, cuya puntuación esperada era un f-score de 0.172 y un Kappa de 0.029.

Por otro lado, tenemos la aplicación de modelos regresores para eliminar artefactos. Como primer trabajo dentro de este rubro, tenemos el propuesto por Zhang et al., [43], autores del banco de datos base EEGdenoiseNet. Su experimentación consistió de un estudio comparativo de diferentes redes neuronales cuyo dominio de la señal EEG fue en el dominio del tiempo. Los métodos evaluados incluyeron: una red neuronal totalmente conectada, que alcanzó un CC de 0.796; una red neuronal convolucional, con un CC de 0.783; una CNN compleja, con un CC de 0.780; una red neuronal recurrente (RNN), con un CC de 0.812; y finalmente, la mejor puntuación de CC fue reportada por una CNN novedosa, con un valor de 0.863, implementada posteriormente al estudio inicial comparativo [44]. En la misma línea de investigación, Huang et al., [26], proponen un modelo de difusión condicional diseñado para la eliminación de ruido en EEG. La red de eliminación es reemplazada por una red de doble rama, donde la información ruidosa del EEG se utiliza como condición para guiar la generación de señales limpias de EEG. Para los experimentos del modelo se emplearon cinco conjuntos de datos: EEGdenoiseNet [45], SSED [46], MNE Sample dataset [47], Resting State EEG Data [48] y Motion Artifact Contaminated EEG Data [49]. Específicamente, esta propuesta superó a modelos de referencia comúnmente utilizados, alcanzando en el conjunto de datos EEGdenoiseNet [45] un RRMSE temporal de 0.182, un RRMSE espectral de 0.188 y un coeficiente de correlación promedio de 0.983. En el siguiente estudio, Azhar et al., [50] diseñaron un modelo que pretende eliminar artefactos oculares y miogénicos, manejando la ocurrencia simultánea de ambos tipos de artefactos usando el conjunto de datos EEGdenoiseNet [45]. Su implementación consiste de una red neuronal convolucional (CNN), la cual logró bajas pérdidas de entrenamiento y validación, con un valor de RRMSE significativamente reducido de 0.35, tanto en los dominios temporal como espectral, y un alto coeficiente de correlación de 0.94. La principal ventaja que mostraron con esta implementación fue que disminuyeron el sobreajuste causado por artefactos de tipo miogénico. Los autores Gabardi et al., [51] desarrollaron

un método que trabaja en el dominio de las frecuencias, donde eliminan artefactos a través de filtros convolucionales óptimos, utilizando el conjunto de datos EEGdenoiseNet [45]. El modelo se entrenó con artefactos tanto EMG como EOG al mismo tiempo para manejar ambos casos. El modelo recibe dos entradas que no interactúan directamente entre sí: las densidades espectrales de potencia y la serie temporal. Para cada paso de convolución, se utilizó un bloque evaluador de kernels, encargado de calcular un conjunto de filtros convolucionales que se aplican a la serie temporal. Los resultados mostraron un CC de 0.805. Asimismo, Lopes et al., [52] implementaron un modelo basado en CNN. El enfoque fue aplicado a registros EEG obtenidos de pacientes epilépticos disponibles en la base de datos EPILEPSIAE. Para la eliminación de artefactos se utilizó el conjunto de datos EEGdenoiseNet, trabajando en el dominio del tiempo. El modelo alcanzó un RMSE de 0.52, la principal desventaja de este modelo es que los artefactos de tipo EMG solo fueron atenuados. Seguidamente, Brophy et al., [53] emplearon una red neuronal antagonista (GAN) para eliminar artefactos de tipo EOG y EMG, utilizando el conjunto de datos EEGdenoiseNet y operando en el dominio del tiempo. Su implementación alcanzó un CC de 0.89. En paralelo con Yi et al., [54] implementó un modelo basado en transformadores 2D. De acuerdo con los autores, la arquitectura aprovecha tanto la auto-similaridad local como no local de las señales EEG mediante bloques de auto-atención y bloques de prealimentación. Utilizando el conjunto de datos EEGdenoiseNet y trabajando en el dominio del tiempo, reportaron un CC de 0.868 para la eliminación de artefactos oculares y un CC de 0.732 para la eliminación de artefactos musculares. En este mismo contexto se encuentra Cui et al., [55], propusieron una red neuronal de fusión interactiva de doble rama, denominada EEGIFNet, para eliminar artefactos en señales EEG monocanal. EEGIFNet emplea dos ramas: una para recuperar la señal EEG limpia y otra para recuperar los artefactos residuales. Cada rama incorpora capas convolucionales y unidades recurrentes bidireccionales con compuertas (BiGRU) en cascada, lo que permite capturar tanto características locales como globales. Utilizando el conjunto de datos EEGdenoiseNet, alcanzaron un CC de 0.792.

Dentro del rubro de modelos de regresión tenemos algunos estudios que solo

eliminaron un tipo de artefacto, cabe señalar que estos enfoques lo que pretenden es aumentar la deficiencia que tienen algunos de los trabajos relacionados mencionados con anterioridad. Como primera investigación, el estudio desarrollado por Choi [56] que presenta un modelo para filtrar la interferencia de EMG de los datos EEG, utilizando un transformador adversarial dirigido por autoencoder (AT-AT). Mencionan que aprovechan un autoencoder para determinar los sitios óptimos de aplicación del transformador de series temporales, la arquitectura AT-AT logra una reducción del tamaño del modelo superior al 90 %. La adición de entrenamiento adversarial asegura que las señales filtradas se adhieran a las características fundamentales de los datos de EEG. Para la experimentación se utilizaron los datos de EEGdenoiseNet [45]. La implementación AT-AT mostró un coeficiente de correlación reconstructiva promedio superior a 0.95 con una relación señal-ruido (SNR) inicial de 2 dB y un SNR de -7 dB. En contraste al estudio desarrollado por Ronca et al., [57] realizó un análisis comparativo de diferentes métodos para eliminar solamente artefactos oculares, ellos en sus resultados solo mencionaron que la corrección de artefactos oculares en señales EEG sigue siendo un desafío importante, especialmente con la expansión del uso de sistemas EEG portátiles en entornos reales.

Desde otra perspectiva se tienen trabajos que usaron otro tipo de conjunto de datos diferente a EEGdenoiseNet y al Corpus TUH EEG, es por ello que se mencionan los siguientes trabajos relacionados. El modelo de clasificación-regresión propuesto por Sikkandar et al., [58], consistió en el desarrollo de un optimizador de Autoencoder Variacional GAN (VA-GAN) para la reducción de artefactos. Este modelo primero reduce las señales EEG crudas a una representación de menor dimensión que captura los patrones esenciales de la señal mientras filtra el ruido. El componente GAN luego refina esta representación a través de un entrenamiento antagónico, minimizando los artefactos. Los conjuntos de datos utilizados en el trabajo fueron dos: CHB-MIT [59] y KAU [60]. Los resultados mostraron una precisión del 98.5 % y una tasa de error del 11.23 %, lo que permite una reconstrucción más clara y precisa de la señal EEG. Posteriormente, tenemos el modelo propuesto por Chuang et al., [5]. Este estudio desarrolló un nuevo método de eliminación de artefactos, IC-U-Net, que se compone del Análisis

de Componentes Independientes (ICA) y una arquitectura de red neuronal U-Net. El modelo no requiere ajuste de parámetros ni designaciones de tipo de artefacto, y no tiene limitaciones en la cantidad de canales. Asimismo, el trabajo propuesto por Bao et al., [61], proponen un modelo para eliminación de artefactos usando un método híbrido. El estudio fue abordado con EEG multicanal, el cual se descompone en varias señales fuente utilizando Análisis de Correlación Canónica. Luego, un módulo de red neuronal profunda elimina automáticamente los artefactos en cada señal fuente. Finalmente, las señales fuente limpias se combinan mediante una suma ponderada para reconstruir las señales EEG. Se utilizó el conjunto de datos EEG semi-sintético [46]. El método híbrido obtuvo una mejora promedio del SNR por canal de 5.20 dB, atribuida principalmente a la información conjunta de los canales, que permitió una mejor preservación de la señal EEG real en regiones distintas. El trabajo propuesto por Mashhadi et al., [62] menciona la implementación de tres tipos de modelos de aprendizaje automático, específicamente U-Net, para eliminar artefactos en señales EEG, en particular artefactos de tipo ocular. Los autores indicaron que utilizaron un conjunto de datos de EEG semi-simulado, en el cual las señales fueron contaminadas manualmente con artefactos oculares. Para el primer método, que obtuvo un MSE de 0.000573, se implementó un modelo por cada canal, obteniendo así un total de 19 modelos U-Net. En el segundo método se obtuvo un MSE de 0.0358, donde se utilizó una matriz de 19x54, siendo 19 los canales y 54 la cantidad de puntos. Finalmente, para el tercer método se alcanzó un MSE de 0.00712 utilizando una matriz de 5400 puntos por 19 canales. Asimismo, el trabajo desarrollado por Aquilué-Llorens & Soria-Frisch [63] presenta un nuevo modelo autoencoder basado en LSTM para la detección y corrección de artefactos en señales EEG. El conjunto de datos empleado para su experimentación fue LEMON Clean/RawFiltered [64]. Este trabajo reportó un RMSE promedio de eliminación de artefactos EOG y EMG de 2.01 y 2.41, respectivamente, para dos conjuntos de datos derivados del conjunto principal. Ahora siguiendo en esta misma línea de acuerdo con Agarwal et al., [65] implementaron un modelo de aprendizaje auto-supervisado permitiendo que los modelos aprendan de grandes cantidades de datos no etiquetados a través de tareas auxiliares, proponiendo un enfoque novedoso para automatizar la identificación y eliminación de artefactos sin necesidad de etiquetado manual.

El modelo aprende de manera independiente características tanto de las señales EEG limpias como de las señales con artefactos, y luego fusiona esta información a través de una red de compuertas adaptativas para generar señales EEG depuradas que preservan con precisión las características de la señal EEG mientras eliminan efectivamente los artefactos. Los principales resultados obtenidos mostraron un CC de 0.9201 para eliminación del artefacto EMG, para EOG 0.9624, para ECTG de 0.9504. Otro estudio, abordado por los autores Kalita et al., [66], propuso un modelo de aprendizaje profundo basado en una GAN denominada AnEEG, que consistió en dos redes neuronales de tipo LSTM para el generador y el discriminador, respectivamente. El conjunto de datos para este trabajo se creó con nueve tipos diferentes de artefactos. Los datos fueron recopilados de cinco sujetos en la Universidad de Gauhati, Assam, India. Los principales resultados reportados por este trabajo mencionan que obtuvieron en promedio un coeficiente de correlación (CC) para parpadeo de ojos de 0.6985, movimiento ocular de 0.6440, masticación de 0.6244 y apretar los dientes de 0.6100. Consecutivamente, Yin et al., [67] propusieron un modelo compuesto por una CNN paralela guiada por una GAN y una red de transformadores. La implementación propuesta alcanzó un coeficiente de correlación de 0.710. Finalmente Xiong et al., [68] implementaron un modelo autoencoder de doble vía que reduce significativamente el esfuerzo computacional, no requiere conocimiento previo de la distribución del ruido ni está limitada por la estructura de la capa de la red, lo cual la convierte en un modelo de red general orientado a la separación ciega de fuentes donde usaron EEGdenoiseNet. El modelo reduce significativamente el esfuerzo computacional y también supera a los algoritmos de eliminación de ruido basados en aprendizaje profundo existentes en métricas de error cuadrático medio relativo (RRMSE), tanto en el dominio del tiempo como en el dominio de la frecuencia.

Ahora bien, los trabajos anteriores basados en aprendizaje profundo abordan la problemática desde una perspectiva de clasificación y/o eliminación de artefactos. Sin embargo, en muchos de estos estudios se descuida el problema de la adaptación de dominio, el cual representa uno de los principales retos en este campo. Una de las dificultades más relevantes es la limitada capacidad de generalización de los modelos

al trabajar con múltiples conjuntos de datos. Las diferencias en la distribución entre los datos de entrenamiento y los de prueba pueden afectar el rendimiento del modelo, lo que dificulta su aplicación en escenarios reales. En este contexto, la adaptación de dominio en redes neuronales tiene una especial relevancia como una estrategia para desarrollar modelos más robustos y precisos. Tal como señalan Saba-Sadiya et al. [4], muchas soluciones existentes requieren que expertos exploren y anoten manualmente los datos para identificar los segmentos contaminados por artefactos en la señal EEG. Además, los autores destacan que se suele asumir que la corrección o eliminación de artefactos es suficiente, bajo la premisa de que la incidencia y características de los artefactos son similares entre todos los sujetos. Este enfoque de talla única limita la capacidad de generalización de los modelos y deja de lado la variabilidad, comprometiéndose así su aplicabilidad en contextos reales y diversos. De acuerdo con lo expuesto por Maiwald et al., [28], se reconoce que la generalización entre dominios es un desafío, y es poco probable que los hallazgos generalicen datos que sean completamente distintos a los datos de EEG empleados inicialmente. Asimismo, Choi [56] destaca que es crucial que estos resultados se generalicen más allá de la implementación inicial y de los casos de prueba semisintéticos presentados en los estudios. También los autores Lu et al., [69] argumentan que los modelos existentes basados en aprendizaje profundo enfrentan desafíos para capturar simultáneamente tanto las características de actividad espacial como las características de topología espacial de las señales EEG. Es por ello que el refinamiento continuo de los algoritmos ha llevado a logros significativos en el tratamiento de señales EEG. Sin embargo, la recopilación de grandes cantidades de datos etiquetados del dominio de destino requiere tiempo considerable, recursos humanos y financieros. Además, estos datos pueden ser extremadamente escasos o incluso insuficientes para realizar ajuste fino, lo que limita el rendimiento y la capacidad de generalización del modelo en la tarea objetivo. Lu et al. [69] propusieron un método de adaptación de dominio que mejora la adaptabilidad al minimizar el error entre dominios y alinear representaciones latentes. No obstante, la mayoría de los métodos actuales se enfocan en extraer características superficiales, sin alinear efectivamente características profundas entre distintos dominios. Adicionalmente, los autores Lu et al., [69] mencionan que un gran desafío surge de la significativa de la variabi-

lidad observada en los datos de los pacientes. Los enfoques específicos por paciente, que se aplican de forma individual, suelen mostrar un rendimiento deficiente cuando se utilizan con otros pacientes debido a esta variabilidad. El objetivo de su estudio es proponer modelos de aprendizaje profundo que puedan manejar esta variabilidad y generalizar de manera efectiva a través de múltiples pacientes.

En la Tabla 1.2 presentamos una comparación entre los diferentes trabajos relacionados, tomando en cuenta los aspectos de interés de este estudio.

#	Autores (año)	Conjunto(s) de datos	Modelo	Enfoque	Tipo de artefacto	Principales resultados
1	Kim & Keene (2019) [41]	TUH EEG Corpus	CNN + LSTM	Clasificación	CHEW, ELPP, EOG, EMG, SHIV	Exactitud 67.59% TPR 80% FAR 25.8% (binaria); inferencia 0.018 s
2	Bahador <i>et al.</i> (2020) [70]	Oulu ICU (UCI)	CNN mapeo RGB	Clasificación	Multiartefacto	AUC = 0.96; Exactitud 92.3 %
3	Mashhadi <i>et al.</i> (2020) [62]	EEG semi-simulado (ocular)	U-Net (3 variantes)	Regresión	EOG	MSE 0.000573 / 0.0358 / 0.00712
4	Saba-Sadiya <i>et al.</i> (2021) [4]	—	Autoencoder (no sup.)	Clasif. + corr.	Multiartefacto	F-score > 0.172; Kappa > 0.0290
5	Zhang <i>et al.</i> (2021) [43]	EEGdenoiseNet	Comparativa	Regresión	EOG, EMG	CC 0.863 (CNN-novel); 0.812 (RNN)
6	Brophy <i>et al.</i> (2021) [53]	EEGdenoiseNet	GAN	Regresión	EOG, EMG	CC 0.89
7	Peh <i>et al.</i> (2022) [40]	TUH EEG Corpus	CNN + Transformer (BMB loss)	Clasificación	CHEW, ELPP, EOG, EMG, SHIV	BAC = 0.947 / 0.735 / 0.826 / 0.857 / 0.655
8	Chuang <i>et al.</i> (2022) [5]	—	IC-U-Net (ICA + U-Net)	Regresión	Multiartefacto	Alto SNR y CC
9	Agarwal <i>et al.</i> (2022) [65]	—	Self-sup. CNN + gating	Regresión	EMG, EOG, ECG	CC 0.9201 (EMG); 0.9624 (EOG); 0.9504 (ECG)
10	Peng Yi <i>et al.</i> (2022) [71]	EEGdenoiseNet	Transformer 2D	Regresión	EOG, EMG	CC 0.868 (EOG); 0.732 (EMG)
11	Maiwald <i>et al.</i> (2023) [28]	TUH EEG Corpus	Xception / EfficientNetB0	Clasificación	CHEW, ELPP, EOG, EMG, SHIV	F1 = 90.5% (Xception); 89.4% (EffNet)
12	Huang <i>et al.</i> (2023) [26]	EEGdenoiseNet; SSSED; MNE; Resting; Motion	Difusión condicional (doble rama)	Regresión	EOG, EMG	RRMSE 0.182 (t), 0.188 (f); CC 0.983
13	Bao <i>et al.</i> (2023) [61]	EEG semi-sintético (SSSED)	CCA + DNN híbrido	Regresión	EOG, EMG	+ 5.20 dB SNR medio por canal
14	Xiong <i>et al.</i> (2023) [68]	EEGdenoiseNet	Autoencoder de doble vía	Regresión	EOG, EMG	Bajo RRMSE
15	Gabardi <i>et al.</i> (2023) [51]	EEGdenoiseNet	CNN dominio frecuencia	Regresión	EOG, EMG	CC 0.805
16	Lopes <i>et al.</i> (2023) [34]	EPILEPSIAE; EEGdenoiseNet	CNN	Regresión	EOG, EMG	RMSE 0.52
17	Yin <i>et al.</i> (2023) [67]	EEGdenoiseNet	CNN Transformer + GAN	Regresión	EOG, EMG	CC 0.710
18	Kalita <i>et al.</i> (2024) [66]	AnEEG	GAN (LSTM Gen/Disc)	Regresión	9 tipos (ocular, etc.)	CC 0.6985 (ojos); 0.6440 (mov. ocular); 0.6244 (masticar); 0.6100 (dientes)
19	Ronca <i>et al.</i> (2024) [57]	—	Filtros conv. óptimos	Regresión	EOG	alto CC y SNR
20	Azhar <i>et al.</i> (2024) [50]	EEGdenoiseNet	CNN	Regresión	EOG, EMG	RRMSE 0.35; CC 0.94
21	Cui <i>et al.</i> (2024) [55]	EEGdenoiseNet	EEGIFNet (CNN + BiGRU)	Regresión	EOG, EMG	CC 0.792
22	Sikkandar <i>et al.</i> (2025) [58]	CHB-MIT; KAU	VA-GAN (VAE + GAN)	Regresión	Multiartefacto	Precisión 98.5%; error 11.23 %
23	Choi (2025) [56]	EEGdenoiseNet	AT-AT (Autoencoder + Transformer adv.)	Regresión	EOG, EMG	CC > 0.95 (2 dB); 0.70 (−7 dB); 90 % tamaño
24	Aquilué-Llorens & Soria-Frisch (2025) [63]	LEMON Clean/RawFiltered	LSTM Autoencoder	Regresión	EOG, EMG	RMSE 2.01 (EOG); 2.41 (EMG)

Cuadro 1.2: Comparativa de métodos de detección y/o eliminación de artefactos en señales EEG.

1.4. Plantamiento del problema

Dado que la electroencefalografía (EEG) es una técnica no invasiva ampliamente utilizada para registrar la actividad eléctrica del cerebro, una de sus principales limitaciones radica que pueden tener artefactos fisiológicos y no fisiológicos, lo que puede degradar significativamente la calidad de la señal EEG registrada. Esta problemática dificulta la extracción de características relevantes y precisas, lo que impacta negativamente en el rendimiento de las aplicaciones basadas en EEG. Los métodos clásicos de filtrado y preprocesamiento suelen aplicar un enfoque de talla única, asumiendo que la incidencia y naturaleza de los artefactos son uniformes entre sujetos. Esta suposición es mencionada por Saba-Sadiya et al. [4], quienes demuestran que la corrección o eliminación de artefactos no es suficiente para preservar la información neuronal subyacente. De forma análoga, Maiwald et al. [28] señalan que los trabajos planteados en el estado del arte rara vez se generalizan a dominios con distribuciones de datos EEG distintos. Además, la alta variabilidad entre las señales EEG de distintos sujetos complica la creación de modelos universales. Esta variabilidad reduce la capacidad de generalización de muchos enfoques actuales, lo que a su vez disminuye la precisión en aplicaciones prácticas. Choi [56] menciona que existe la necesidad de validar los resultados más allá de configuraciones iniciales y conjuntos de prueba. Además el encontrar una solución de equilibrio entre la eliminación de artefactos y la preservación de señales relevantes representa un desafío constante. Técnicas avanzadas como el aprendizaje profundo y la adaptación de dominio han demostrado mejorar la identificación y eliminación de artefactos y aumentando la robustez de las aplicaciones EEG.

Entonces podemos plantear el problema, de acuerdo con Yadav et al., [72] y Kawala-Sterniuk et al., [2] los artefactos presentes en señales EEG, considera la siguiente ecuación 1.21 donde la señal EEG medida puede modelarse como la suma de la señal determinista real y un componente que son los artefactos no deseados, de la siguiente forma:

$$x(t) = s(t) + n(t) \quad (1.21)$$

Donde $x(t)$ es la señal EEG observada, $s(t)$ representa la señal EEG determinada real, y $n(t)$ corresponde a los artefactos no deseados presentes en la señal. Por lo tanto, el objetivo principal es identificar, eliminar o atenuar la presencia de $n(t)$ para recuperar la señal $s(t)$ de manera más precisa.

1.5. Marco de trabajo

En la figura 1.7 se presenta el marco de trabajo propuesto dividido en 4 bloques principales para el desarrollo del presente proyecto de investigación.

Para la fase 1, se lleva a cabo el preprocesamiento de los datos. Se utilizan tanto señales EEG con artefactos reales que serán el dominio fuente, así como señales EEG semi-sintéticas que serán el dominio objetivo para aumentar la variabilidad que se necesita del modelo. En cuanto a la adaptación de dominio, a cada señal se le realizó un corte o relleno para alcanzar una longitud de 512 muestras, lo que equivale a 1 segundo. Posteriormente, el conjunto de datos se divide en un 80% para entrenamiento y un 20% para pruebas. Para la etapa de división de los datos, es importante mantener la misma cantidad de datos en cuanto a los artefactos para poder hacer una alineación entre dominios. Para la fase 2, se lleva a cabo el proceso de transformación de las señales EEG que están en el dominio del tiempo al dominio tiempo-frecuencia. Para ello, se aplica la Transformada de Fourier de Tiempo Corto (STFT) para posteriormente extraer únicamente la magnitud del espectro. Los parámetros de la STFT iniciales fueron una ventana de 128 puntos con un desplazamiento entre ellas de 64 puntos. La magnitud representa la intensidad de los componentes frecuenciales en función del tiempo. Finalmente, en esta etapa se aplica una normalización de tipo z-score. La fase 3 corresponde a la etapa de entrenamiento y validación del modelo de aprendizaje con adaptación de dominio para la tarea de clasificación (RestNet) y regresión (difusión estable). Durante esta etapa se incluirá la adaptación de dominio usando en conjunto dos funciones de costo, como la entropía cruzada y Sinkhorn para el caso de la tarea de clasificación, y para el caso de regresión, se cambiará la función de entropía cruzada por la función de error cuadrático medio, permitiendo al modelo generalizar un mejor rendimiento de identificación y eliminación de artefactos en la señal EEG. Para

la parte de evaluación del modelo se usarán las métricas de clasificación como exactitud, precisión, recall y F1-Score; para la tarea de regresión se evaluará el modelo con error cuadrático medio (RMSE), error absoluto medio (MAE) y mediante el coeficiente de correlación. Como fase final, se desarrollará una herramienta de visualización que permitirá la visualización en tiempo real de los artefactos detectados en señales EEG multicanal. Esta herramienta mostrará la señal EEG original junto con los artefactos detectados por el modelo, permitiendo a profesionales observar dónde ocurren dichos eventos.

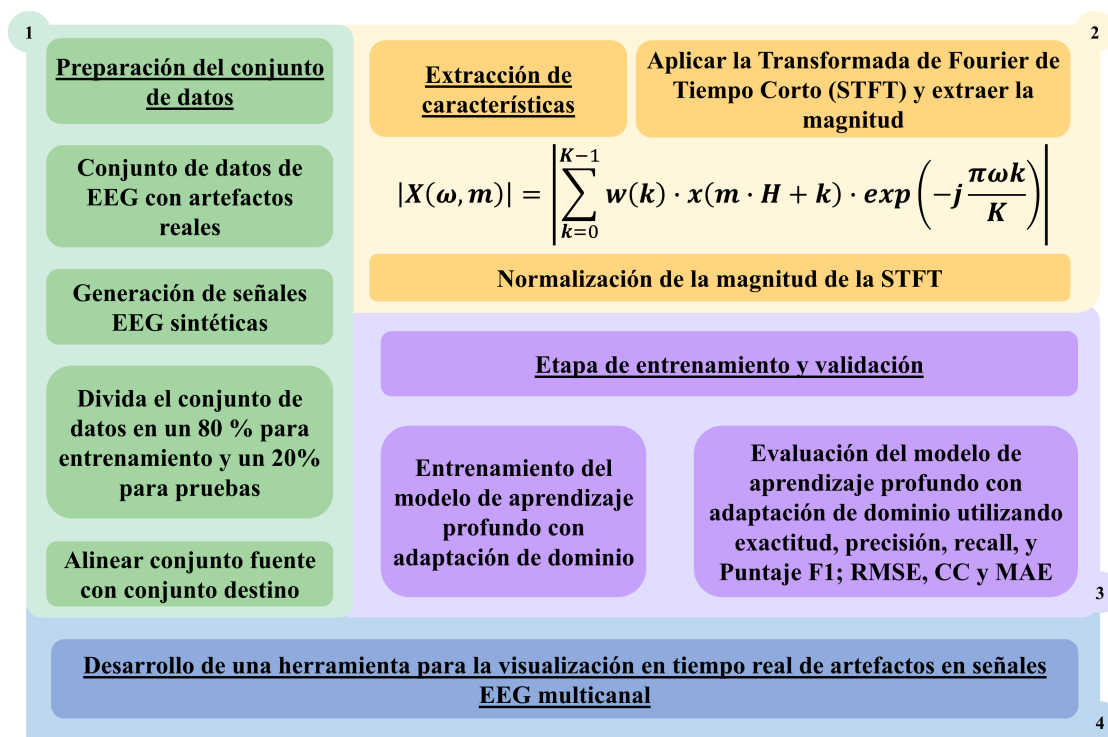


Figura 1.7: Marco de trabajo propuesto para la clasificación, detección e eliminación de artefactos en señales de EEG. Los bloques se dividen en preprocesamiento de señales de EEG, extracción de características, evaluación del modelo propuesto y desarrollo de una herramienta de visualización en tiempo real.

1.6. Justificación

La investigación en la mejora de identificación y eliminación de artefactos en señales de electroencefalografía (EEG) utilizando técnicas de aprendizaje profundo y adaptación de dominio presenta las principales razones que justifican esta investiga-

ción:

- Mejorar la precisión de estas señales es crucial para aplicaciones críticas, como en el área clínica y/o en el campo de las interfaces cerebro-computadora, donde se requiere una exactitud mejorada para interpretar correctamente los datos presentes en las señales.
- Un enfoque mejorado para la detección y eliminación de artefactos aplicando adaptación de dominio en el método de aprendizaje mejora la efectividad y usabilidad ampliando su aplicabilidad en tiempo real.
- Actualmente, los métodos tradicionales de preprocesamiento de señales EEG presentan limitaciones en la eliminación de artefactos y preservación de información relevante además que los modelos existentes parten de ser talla única es decir no hay consideración de entrenar los modelos con variabilidad.

1.7. Preguntas de investigación

A continuación, se plantean una serie de preguntas de investigación que guiarán el desarrollo de la presente propuesta de investigación.

- ¿El problema de eliminación de artefactos en señales EEG se aborda como una tarea de clasificación y/o de regresión?
- ¿Qué métodos supervisados, no supervisados y semi-supervisados existen en el estado del arte para la eliminación de artefactos en señales EEG?
- ¿Qué técnicas de extracción de características de señales EEG ayudan a tener un menor sesgo en el desempeño de los modelos de aprendizaje profundo?
- ¿Es posible ajustar los parámetros de los modelos de aprendizaje profundo durante el entrenamiento para que sea capaz de generalizar en la identificación y eliminación de artefactos en señales de EEG, considerando variabilidad entre los conjuntos de datos?
- ¿De qué manera la adaptación de dominio en los modelos de aprendizaje pueden

mejorar la eficacia de los métodos de eliminación de artefactos en señales EEG en contextos de variabilidad entre conjunto de datos?

1.8. Objetivo general

Desarrollar y evaluar un enfoque basado en técnicas de aprendizaje profundo con adaptación de dominio, con el fin de mejorar la clasificación y eliminación de artefactos fisiológicos y no fisiológicos en señales de electroencefalografía.

1.8.1. Objetivos particulares

- Comparar técnicas de aprendizaje profundo existentes en el estado del arte para la clasificación y eliminación de artefactos en señales EEG.
- Analizar qué enfoque basado en clasificación y/o de regresión ofrece un mejor rendimiento para la detección y eliminación efectiva de artefactos en señales EEG.
- Implementar y comparar diferentes métodos de preprocesamiento de señales EEG para identificar aquellos que ofrecen una mejor reducción de artefactos y preservación de características relevantes.
- Analizar los resultados obtenidos para evaluar la eficacia de los enfoques desarrollados de adaptación de dominio en tareas de clasificación y regresión, considerando precisión, robustez y capacidad de generalización de artefactos en las señales EEG.
- Implementar el modelo en hardware para realizar predicciones en tiempo real para detectar y/o eliminar artefactos.

1.9. Hipótesis

H0: La implementación de un enfoque que combine técnicas de aprendizaje profundo con adaptación de dominio mejorará el desempeño en un 5% de clasifica-

ción y eliminación de artefactos en señales EEG respecto al estado del arte, lo que resultará en una mejor comprensión de la señal EEG para sus diferentes aplicaciones.

1.10. Alcance

El alcance de esta investigación abarca el desarrollo, evaluación y implementación de un enfoque que utiliza técnicas de aprendizaje profundo y adaptación de dominio para mejorar la eliminación de artefactos en señales de electroencefalografía. La investigación incluirá:

- La revisión sistemática de la literatura, así como la selección o adaptación de técnicas de aprendizaje profundo para la eliminación de artefactos en señales EEG.
- El diseño y desarrollo de un modelo de adaptación de dominio que mejore la robustez del sistema frente a la variabilidad y condiciones cambiantes.
- La implementación de diferentes métodos de preprocesamiento de señales EEG y su comparación en términos de reducción de artefactos y preservación de características relevantes.
- Experimentación para evaluar la efectividad del enfoque propuesto en la eliminación de artefactos.
- La evaluación del rendimiento del enfoque propuesto respecto a lo reportado en el estado del arte.

1.11. Contribuciones

El presente proyecto de investigación plantea las siguientes contribuciones, las cuales se enlistan a continuación:

- Se propondrá y validará un enfoque que combine técnicas de aprendizaje profundo y adaptación de dominio para la eliminación de artefactos en señales EEG, mejorando así la calidad de las señales para sus aplicaciones.

- Se desarrollará un modelo de adaptación de dominio que permita una mejor generalización de eliminación de ruido en EEG contribuyendo al campo de la adaptación de dominio en aplicaciones biomédicas.

1.12. Cronograma de actividades

En la 1.3 se muestra el cronograma de actividades que se desarrollarán durante el periodo del Doctorado en Ciencias en Ciencias de Datos. Asimismo, se detalla el tiempo y el orden en que se realizará cada actividad.

Cuadro 1.3: Cronograma de actividades

Actividades	Semestre							
	1	2	3	4	5	6	7	8
1. Revisión sistemática de la literatura	✓	✓	✓	✓				
2. Definición del problema, justificación, objetivos, alcance	✓	✓						
3. Redacción del protocolo de investigación	✓	✓						
4. Redacción de la sección de trabajos relacionados	✓	✓						
5. Redacción del marco teórico		✓	✓	✓	✓			
6. Recolección de datos	✓	✓						
7. Desarrollo de la experimentación		✓	✓	✓				
8. Redacción y envío de artículo para congreso internacional			✓	✓				
9. Pruebas y análisis de resultados		✓	✓	✓				
10. Redacción y envío de artículo JCR						✓	✓	✓
11. Redacción de documento de tesis	✓	✓	✓	✓	✓	✓	✓	✓

1.13. Materiales y métodos

En esta sección se presenta la propuesta de solución al planteamiento del problema de clasificación e eliminación de artefactos mediante aprendizaje profundo.

1.13.1. Propuesta de solución al plantamiento del problema

El algoritmo 3 se basa en investigaciones previas de otros campos como [21], [73], [19], [1]. Este algoritmo está diseñado para entrenar redes neuronales profundas que cuenten con capas lineales de neuronas totalmente conectadas para llevar a cabo mecanismos de adaptación, con el objetivo de hacer más robustas las tareas de clasificación y regresión. La adaptación de dominio comprende un conjunto de técnicas destinadas a alinear las distribuciones latentes de las redes neuronales en presencia de cambios de covariables en los datos. Para ello, se requiere de las características de los datos en ambos dominios (fuente y objetivo), aunque solo se dispone de etiquetas para el dominio fuente. El entrenamiento es de tipo no supervisado, ya que a partir del conjunto etiquetado del dominio fuente, y utilizando funciones de pérdida como la entropía cruzada o el error cuadrático medio, se puede realizar la adaptación mediante la extracción de un vector latente de la red neuronal y la pérdida del método Sinkhorn. Las distribuciones latentes se refieren a las distribuciones de probabilidad sobre estos vectores latentes, y durante el entrenamiento, la adaptación de dominio minimiza una medida de distancia estadística entre ellas.

El proceso inicia con la alineación de la matriz de características del dominio fuente x_s y del dominio objetivo x_t , denotadas conjuntamente como $X = x_s, x_t$. A continuación, el modelo (ver figura 1.8) genera predicciones para cada dominio: $y_s, y_t \leftarrow Y$. En la sección correspondiente a las capas totalmente conectadas del modelo, se selecciona una capa intermedia de la cual se extraen las representaciones latentes: $z_s, z_t \leftarrow Z$, correspondientes a ambos dominios. El objetivo de este último paso es alinear las representaciones de los dominios de origen y destino. Utilizando estos vectores de características, se calcula la distancia euclidiana entre ellos, la cual se utiliza en la función de Sinkhorn para calcular el costo mínimo entre las distribuciones latentes de ambos dominios. El propósito de esta función es alinear las distribuciones del dominio fuente y del dominio objetivo durante el entrenamiento, de forma que el modelo sea capaz de generalizar correctamente en ambos dominios. Una vez efectuados estos cálculos, se selecciona la función de pérdida adecuada de acuerdo con la naturaleza de la tarea (clasificación o regresión). En el siguiente paso, se suman tanto la pérdida de

adaptación de dominio como la pérdida de predicción de la red neuronal. Finalmente, esta pérdida total se utiliza para calcular los gradientes y actualizar los parámetros del modelo durante el proceso de entrenamiento.

Algoritmo 3: Adaptación de dominio para tareas de clasificación y regresión no supervisada usando la pérdida de Sinkhorn - TO [1]

Entrada: x_s : Entradas del dominio fuente, y_s : Etiquetas verdaderas del dominio fuente, x_t : Entradas del dominio objetivo, n : Tamaño de lote por dominio, λ_{DA} : Peso de la pérdida de dominio

```

while no converge do
     $X \leftarrow [x_s, x_t]$ 
     $Y, Z \leftarrow \text{modelo}(X)$ 
     $y_{s,-} \leftarrow Y$ 
     $z_s, z_t \leftarrow Z$ 
     $\mathcal{L}_{DA} \leftarrow \text{Sinkhorn}(z_s, z_t, \|z_{s_i} - z_{t_j}^*\|_2, \epsilon)$ 
     $\mathcal{L}_{CE} \leftarrow \text{CrossEntropy}(y_s, \hat{y}_s)$ 
     $\mathcal{L}_{MSE} \leftarrow \text{MeanSquareError}(y_s, \hat{y}_s)$ 
     $\mathcal{L} \leftarrow \mathcal{L}_{task} + \lambda_{DA} \cdot \mathcal{L}_{DA}$ 
    loss.backward()
    optimizer
end

```

La pérdida de Sinkhorn [1] internamente trabaja con el algoritmo 4. El algoritmo recibe como parámetros iniciales los vectores latentes x_s y x_t . Además, a partir de estos vectores, se calcula la matriz de costos C_{ij} , definida como la distancia euclidiana. Posteriormente, se define el parámetro de entropía $\epsilon > 0$, se establece como parámetro de entrada el número máximo de iteraciones T y, finalmente, el criterio de convergencia $\delta > 0$. A continuación, se define un kernel que utiliza la matriz de costos C_{ij} y el parámetro ϵ . El siguiente paso es inicializar dos vectores positivos $u^{(0)}$ y $v^{(0)}$, que actúan como factores de corrección de las distribuciones α y β . En cada iteración del ciclo se actualizan los vectores $u^{(t+1)}$ y $v^{(t+1)}$. Estas actualizaciones de parámetros se repiten hasta alcanzar T iteraciones o hasta que se cumpla δ en la norma ℓ_1 . Una vez alcanzada la convergencia, se calcula el plan de transporte $\pi^{(*)}$. Posteriormente, se calcula el costo de entropía regularizado combinando el transporte y la penalización de la entropía. Finalmente, para obtener la pérdida de Sinkhorn se corrige el sesgo de entropía garantizando que $S_\epsilon(\alpha, \alpha) = 0$ y positividad definida.

Algoritmo 4: Cálculo de pérdida Sinkhorn

Entrada: $\alpha \in \Delta_n$: pesos de la primera medida,
 $\beta \in \Delta_m$: pesos de la segunda medida,
 $C \in \mathbb{R}^{n \times m}$: matriz de costes,
 $\varepsilon > 0$: parámetro de entropía,
 T : número máximo de iteraciones,
 $\delta > 0$: tolerancia de convergencia

Salida : $S_\varepsilon(\alpha, \beta)$: divergencia Sinkhorn

$K_{ij} \leftarrow \exp(-C_{ij}/\varepsilon)$

$u^{(0)} \leftarrow \mathbf{1}_n, \quad v^{(0)} \leftarrow \mathbf{1}_m$

for $t \leftarrow 0, 1, \dots, T-1$ **do**

$u^{(t+1)} \leftarrow \alpha \oslash (K v^{(t)})$

$v^{(t+1)} \leftarrow \beta \oslash (K^\top u^{(t+1)})$

if $\|u^{(t+1)} - u^{(t)}\|_1 + \|v^{(t+1)} - v^{(t)}\|_1 \leq \delta$ **then**
 | **break**

end

end

$\pi^* \leftarrow \text{diag}(u^{(T)}) K \text{diag}(v^{(T)})$

$\text{OT}_\varepsilon(\alpha, \beta) \leftarrow \sum_{i,j} \pi_{ij}^* C_{ij} - \varepsilon \sum_{i,j} \pi_{ij}^* (\log \pi_{ij}^* - 1)$

$S_\varepsilon(\alpha, \beta) \leftarrow \text{OT}_\varepsilon(\alpha, \beta) - \frac{1}{2} \text{OT}_\varepsilon(\alpha, \alpha) - \frac{1}{2} \text{OT}_\varepsilon(\beta, \beta)$

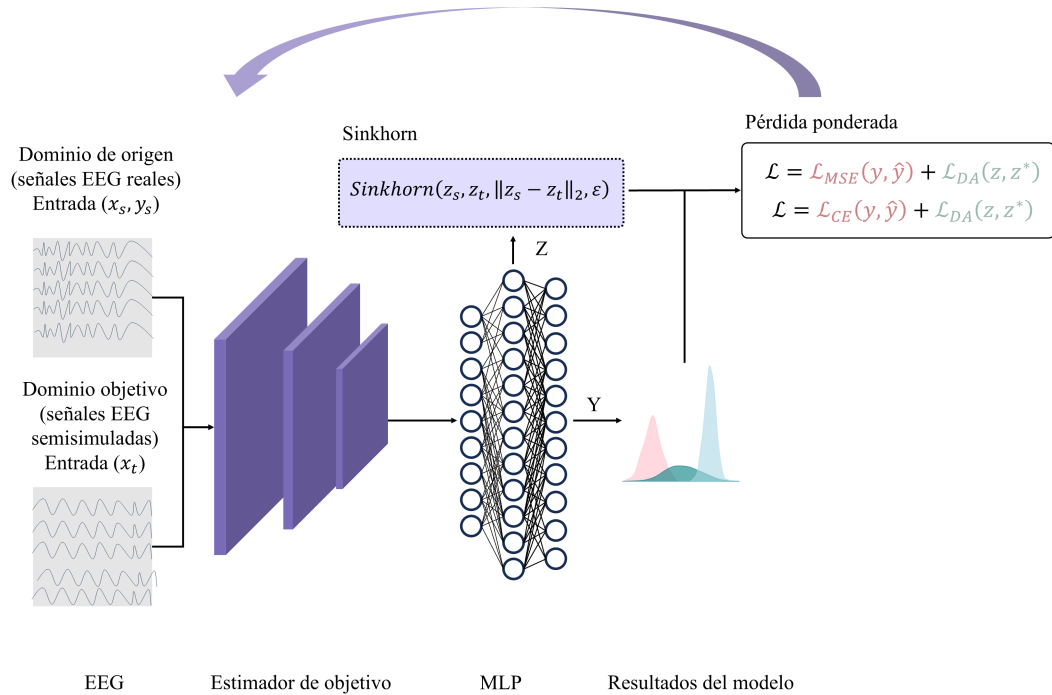


Figura 1.8: Arquitectura de red neuronal implementada y método de entrenamiento de adaptación de dominio para tareas de clasificación y regresión

1.14. Resultados parciales

En la figura 1.9 se muestra el comportamiento de la métrica de exactitud del modelo de aprendizaje profundo con adaptación de dominio. El modelo fue entrenado durante 70 épocas utilizando los conjuntos de datos del dominio fuente (TUH EEG [27]) y del dominio objetivo (EEGdenoiseNet [45]), empleando el 80% de los datos para la fase de entrenamiento y el 20% restante para la fase de prueba. La curva de exactitud del dominio fuente en la fase de entrenamiento, representada con marcadores de color azul, alcanza valores cercanos al 99%, lo que indica que el modelo está aprendiendo de manera efectiva. Por otro lado, la curva de exactitud correspondiente a los datos de entrenamiento del dominio objetivo, marcada en color naranja, alcanza una exactitud aproximada del 94%. Para los datos de prueba del dominio fuente representados por la línea de color verde, la curva logra estabilizarse en un rango cercano al 90–91%. Finalmente, la línea en color rojo corresponde a los datos del conjunto de prueba del dominio objetivo, alcanzando un 93% en la métrica de exactitud. En general, el comportamiento del modelo a lo largo de las épocas de entrenamiento muestra una convergencia estable, sin oscilaciones ni caídas abruptas que degraden el rendimiento, tanto en el dominio fuente como en el dominio objetivo.

La figura 1.10 muestra el comportamiento de tres métricas a lo largo de las épocas de entrenamiento del modelo de aprendizaje de adaptación de dominio. Las métricas como la divergencia de Kullback-Leibler (KL) [37], la divergencia de Jensen-Shannon (JS) [38] y la distancia de Jensen-Shannon [39]. Estas tres métricas indican que el modelo ha aprendido a alinear las distribuciones del dominio fuente y del dominio objetivo además demuestra que la estrategia de adaptación reduce eficazmente la disparidad entre dominios y conserva esa concordancia estadística durante el resto del entrenamiento, lo que ayuda a mejorar la capacidad de generalización del modelo.

Las figuras 1.11 y 1.12 se muestran las matrices de confusión obtenidas para la tarea de detección automática de artefactos en señales EEG usando el conjunto de validación. En las figuras se muestra el rendimiento del modelo para el dominio fuente (figura 1.11) y el dominio objetivo (figura 1.12).




Figura 1.9: Comportamiento de exactitud durante el entrenamiento de la red neuronal con adaptación de dominio (dominio fuente y dominio objetivo con los conjuntos de entrenamiento y validación).

La figura 1.11 representa las clases del dominio fuente. En ella se observa que la clase de masticación alcanza una precisión del 87 %, aunque un 9 % de los datos se confunden con la clase de movimiento muscular. Por otro lado, el desprendimiento de un electrodo presenta una precisión del 97 %, pero un 3 % de las instancias son clasificadas erróneamente como artefacto de mareo. En el caso de la clase de movimiento ocular, se obtiene una precisión del 97 %. El artefacto de tipo muscular alcanza un 86 % de precisión, aunque un 10 % de los casos son confundidos con artefactos de masticación. Finalmente, el artefacto de temblor presenta una exactitud del 89 %, con un 11 % de las instancias clasificadas erróneamente como otros artefactos.

La figura 1.12 muestra el rendimiento general sobre el conjunto de datos objetivo para la detección de diferentes artefactos en la señal EEG. En primer lugar, el artefacto de masticación alcanza una exactitud del 88 %, aunque presenta una pérdida del 12 % debido a clasificaciones incorrectas en otras clases. En el caso del artefacto

Métricas de Divergencia y Distancia




Figura 1.10: Comportamiento de Divergencias y Distancias entre Distribuciones a lo largo de las Épocas del Entrenamiento de la Red Neuronal.

por desprendimiento de electrodo, se obtiene una detección correcta del 80 %, mientras que el 20 % restante fue clasificado erróneamente. Para los artefactos de movimiento ocular y muscular, se alcanzaron exactitudes del 95 % y 92 %, respectivamente. Finalmente, el artefacto de temblor obtuvo una exactitud del 90 %, con un 10 % de las instancias confundidas con otros tipos de artefactos.

La figura 1.13 muestra la herramienta empleada para una visualización multicanal de señales de electroencefalografía, utilizada en la detección de artefactos. La señal EEG mostrada en dicha figura corresponde a una señal EEG generada a partir de los conjuntos de datos EEGdenoiseNet [45] y TUH EEG [27], a la cual se le añadieron artefactos utilizando el algoritmo 3. Esta señal contiene múltiples electrodos conforme al sistema 10-20. Cada línea en la gráfica representa la actividad de un canal específico, donde se observa una superposición de artefactos fisiológicos y no fisiológicos a lo largo del tiempo. El objetivo de esta herramienta es permitir un etiquetado automático que indique la presencia de artefactos en cada segmento, con fines de análisis poste-

rior. En la figura 1.13 también se muestran las leyendas de los artefactos que el modelo puede detectar. En este caso, se identifican segmentos de señal EEG afectados por movimientos de masticación, interrupciones en el contacto del electrodo, movimientos oculares o parpadeos, actividad muscular y artefactos producidos por temblores.

Ahora en la figura 1.14 se muestra la misma herramienta de la figura 1.13 de detección de artefactos bajo una tarjeta Raspberry Pi 4. Se decidió llegar a esta implementación dado que en el estado del arte los autores Kim & Keene [41] plantearon usar Raspberry Pi para llevar a cabo inferencias con el modelo para detección de artefactos en señales EEG, ellos mencionaron que su modelo contiene 65 MB de parámetros, lo que permite su implementación usarse en dispositivos portátiles como Raspberry Pi. Dado que el modelo de aprendizaje de adaptación de dominio propuesto en esta investigación alcanza un tamaño de ≈ 43 MB y además logra generalizar en dos dominios distintos, podemos afirmar que la implementación es lo suficientemente robusta como para ser utilizada en este tipo de dispositivos.

En las Tablas 1.4 y 1.5 se presentan los resultados obtenidos sobre el conjunto de validación para los dominios fuente y objetivo, respectivamente. Dichas tablas muestran las métricas de evaluación del modelo de aprendizaje profundo con adaptación de dominio, incluyendo exactitud, precisión, sensibilidad, puntaje F1 y especificidad. Comenzando con la clase masticación, se observa una precisión de 0.8269 en el dominio fuente y de 0.8992 en el dominio objetivo. Por otro lado, las clases con los artefactos de explosión de electrodo y artefacto ocular, alcanzaron una precisión de 0.9750 y 0.9189 en el dominio fuente, y de 0.9697 y 0.9318 en el dominio objetivo, respectivamente. Finalmente, los artefactos de movimiento muscular y de temblor, obtuvieron una precisión de 0.8513 y 0.9042 en el dominio fuente, y de 0.9612 y 0.8721 en el dominio objetivo, respectivamente. Lo que podemos concluir para esta parte de la experimentación de clasificación de artefactos es que el modelo está generalizando de forma adecuada tanto datos del dominio fuente como datos del dominio destino. Entonces, la implementación de técnicas como la adaptación de dominio, así como el uso de espectrogramas, proporciona un mejor rendimiento.

En la tabla 1.6 se presenta una comparación del promedio de exactitud alcan-

Cuadro 1.4: Resultados por clase del dominio fuente

Clase	Exactitud	Precisión	Sensibilidad	Puntaje F1	Especificidad
EEG	0.9872	0.9977	0.9451	0.9707	0.9994
Masticación	0.9350	0.8269	0.8734	0.8495	0.9514
Explosión de Electrodo	0.9995	0.9750	0.9750	0.9750	0.9998
Movimiento Ocular	0.9660	0.9189	0.9210	0.9200	0.9781
Músculo	0.9318	0.8513	0.8558	0.8535	0.9548
Temblor	0.9771	0.9042	0.8904	0.8972	0.9881

Cuadro 1.5: Resultados por clase del dominio objetivo

Clase	Exactitud	Precisión	Sensibilidad	Puntaje F1	Especificidad
EEG	0.9894	0.9587	0.9956	0.9768	0.9876
Masticación	0.9537	0.8992	0.8781	0.8885	0.9738
Explosión de Electrodo	0.9978	0.9697	0.8000	0.8767	0.9998
Movimiento Ocular	0.9751	0.9318	0.9524	0.9420	0.9813
Músculo	0.9729	0.9612	0.9205	0.9404	0.9888
Temblor	0.9737	0.8721	0.8969	0.8843	0.9834

zados por diferentes métodos de clasificación de artefactos presentes en la señal EEG, además del método implementado junto al tipo de características usadas para el entrenamiento del modelo. En esta tabla se destaca el rendimiento del modelo propuesto para la clasificación de artefactos, el modelo propuesto alcanza en promedio una exactitud del 89.84 %, superando ligeramente a métodos existentes. En segundo lugar se encuentra Densenet201, el cual también se basa en espectrogramas, reportando una exactitud del 88.30 %. Los modelos CNN + Transformer y Ensamble LSTM + 2 CNN mostraron un rendimiento inferior del 79.22 % y 67.59 %, respectivamente, utilizando características estadísticas del EEG en estado base o señales EEG en estado base. Las representaciones espectrales otorgan una ventaja de aprendizaje en la tarea de clasificación de artefactos, alcanzando así una mejor eficacia.

Cuadro 1.6: Comparación del promedio de exactitud entre diferentes métodos.

Método	Tipo de características	Promedio de Precisión (%)
Propuesta RestNet con AD	Espectrograma	89.84
Densenet201 [28]	Espectrograma	88.30
CNN + Transformer [40]	Estadísticas de EEG en estado base	79.22
Ensamble LSTM + 2 CNN [28]	EEG en estado base	67.59

1.15. Conclusiones parciales

De acuerdo con el problema planteado, hasta el momento se ha desarrollado un primer modelo que cumple con el objetivo principal de este trabajo que es la adaptación de dominio. Como se mostró en la etapa de resultados, se logró implementar una estrategia de adaptación utilizando dos conjuntos de datos. El primer conjunto fue utilizado como dominio fuente, permitiendo entrenar un modelo capaz de clasificar e identificar artefactos en registros de pacientes reales. Por otro lado, el segundo conjunto de datos, considerado como dominio objetivo, fue empleado con el fin de incrementar la capacidad de generalización del modelo. Este segundo conjunto fue sometido a un proceso de modificación del nivel de SNR para simular condiciones adversas de los artefactos. Con esto se aborda el problema de los modelos diseñados bajo un enfoque de “talla única”, permitiendo que nuestra propuesta mantenga un rendimiento adecuado ante distintas condiciones de entrada. Adicionalmente, debido a que el modelo propuesto presenta una arquitectura eficiente, tanto en cantidad como en tamaño de parámetros, se logró su implementación en hardware de bajo costo, como una Raspberry Pi. Esta implementación permitió el desarrollo de un dispositivo funcional que no solo adquiere la señal EEG en tiempo real, sino que también visualiza en tiempo real la detección de artefactos. Finalmente, se espera que los resultados obtenidos sirvan como base para la segunda fase del proyecto que es la de mitigar o eliminar los artefactos mediante un modelo de regresión. En esta etapa, se prevé utilizar el conjunto de datos semi-sintéticos como dominio fuente, lo cual permitiría un mayor control y precisión en la eliminación de los artefactos, garantizando una adaptación efectiva hacia datos reales en el dominio objetivo.




Figura 1.11: Matriz de confusión del dominio fuente en el conjunto de validación en la detección de artefactos.




Figura 1.12: Matriz de confusión del dominio objetivo en el conjunto de validación en la detección de artefactos.




Figura 1.13: Visualización multicanal de señales EEG con etiquetas de artefactos.




Figura 1.14: Inferencias y visualización multicanal de señales EEG con etiquetas de artefactos en una Raspberry Pi.

Bibliografía

- [1] J. Feydy, T. Séjourné, F.-X. Vialard, S.-i. Amari, A. Trounev, and G. Peyré, “Interpolating between optimal transport and mmd using sinkhorn divergences,” in *The 22nd International Conference on Artificial Intelligence and Statistics*, 2019, pp. 2681–2690.
- [2] A. Kawala-Sterniuk, N. Browarska, A. Al-Bakri, M. Pelc, J. Zygarlicki, M. Sidikova, R. Martinek, and E. J. Gorzelanczyk, “Summary of over fifty years with brain-computer interfaces—a review,” *Brain Sciences*, vol. 11, no. 1, p. 43, Jan 2021.
- [3] J. Yu, C. Li, K. Lou, C. Wei, and Q. Liu, “Embedding decomposition for artifacts removal in eeg signals,” *Journal of Neural Engineering*, vol. 19, no. 2, p. 026052, apr 2022. [Online]. Available: <https://dx.doi.org/10.1088/1741-2552/ac63eb>
- [4] S. Saba-Sadiya, E. Chantland, T. Alhanai, T. Liu, and M. M. Ghassemi, “Unsupervised eeg artifact detection and correction,” *Frontiers in Digital Health*, vol. 2, 2021. [Online]. Available: <https://www.frontiersin.org/journals/digital-health/articles/10.3389/fdgth.2020.608920>
- [5] C.-H. Chuang, K.-Y. Chang, C.-S. Huang, and T.-P. Jung, “Ic-u-net: A u-net-based denoising autoencoder using mixtures of independent components for automatic eeg artifact removal,” *NeuroImage*, vol. 263, p. 119586, November 2022, epub ahead of print, August 27, 2022.
- [6] N. Alharbi, “A novel approach for noise removal and distinction of eeg recordings,” *Biomedical Signal Processing and Control*, vol. 39, pp. 23–33, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S174680941730143X>
- [7] A. F. Jackson and D. J. Bolger, “The neurophysiological bases of eeg and eeg measurement: a review for the rest of us,” *Psychophysiology*, vol. 51, no. 11, pp. 1061–1071, Nov. 2014, epub 2014 Jul 17.

- [8] A. Ahmed, "A quick survey of eeg signal noise removal methods," *Global Journal of Engineering and Technology Advances*, vol. 11, pp. 098–104, 06 2022.
- [9] M. Jurczak, M. Kołodziej, and A. Majkowski, "Implementation of a convolutional neural network for eye blink artifacts removal from the electroencephalography signal," *Frontiers in Neuroscience*, vol. 16, 2022. [Online]. Available: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2022.782367>
- [10] Y. Cai, Z. Meng, and D. Huang, "Dhct-gan: Improving eeg signal quality with a dual-branch hybrid cnn–transformer network," *Sensors*, vol. 25, no. 1, 2025. [Online]. Available: <https://www.mdpi.com/1424-8220/25/1/231>
- [11] A. F. Jackson and D. J. Bolger, "The neurophysiological bases of EEG and EEG measurement: a review for the rest of us," *Psychophysiology*, vol. 51, no. 11, pp. 1061–1071, Nov. 2014.
- [12] D. L. Schomer and F. H. Lopes da Silva, Eds., *Niedermeyer's electroencephalography*, 7th ed. New York, NY: Oxford University Press, Mar. 2018.
- [13] S. Sanei and J. A. Chambers, *EEG Signal Processing*. New York: Wiley-Interscience, May 2013.
- [14] O. I. Abiodun, A. Jantan, A. E. Omolara, K. V. Dada, N. A. Mohamed, and H. Arshad, "State-of-the-art in artificial neural network applications: A survey," *Heliyon*, vol. 4, no. 11, p. e00938, 2018. [Online]. Available: <https://doi.org/10.1016/j.heliyon.2018.e00938>
- [15] X. Yao, "A review of evolutionary artificial neural networks," *Int. J. Intell. Syst.*, vol. 8, no. 4, pp. 539–567, 1993.
- [16] M. G. M. Abdolrasol, S. M. S. Hussain, T. S. Ustun, M. R. Sarker, M. A. Hannan, R. Mohamed, J. A. Ali, S. Mekhilef, and A. Milad, "Artificial neural networks based optimization techniques: A review," *Electronics (Basel)*, vol. 10, no. 21, p. 2689, Nov. 2021.
- [17] H. Guan and M. Liu, "Domainatm: Domain adaptation toolbox for medical data analysis," *NeuroImage*, vol. 268, p. 119863, 2023. [Online]. Available:

<https://www.sciencedirect.com/science/article/pii/S1053811923000125>

- [18] N. Courty, R. Flamary, A. Habrard, and A. Rakotomamonjy, "Joint distribution optimal transportation for domain adaptation," 2017. [Online]. Available: <https://arxiv.org/abs/1705.08848>
- [19] H.-Y. Lin, H.-H. Tseng, X. Lu, and Y. Tsao, "Unsupervised noise adaptive speech enhancement by discriminator-constrained optimal transport," 2021. [Online]. Available: <https://arxiv.org/abs/2111.06316>
- [20] G. Wilson and D. J. Cook, "A survey of unsupervised deep domain adaptation," *ACM Transactions on Intelligent Systems and Technology*, vol. 11, no. 5, pp. 1–46, Sep. 2020, epub 2020 Jul 5. [Online]. Available: <https://doi.org/10.1145/3400066>
- [21] N. Courty, R. Flamary, D. Tuia, and A. Rakotomamonjy, "Optimal transport for domain adaptation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 9, pp. 1853–1865, 2017.
- [22] P. Singhal, R. Walambe, S. Ramanna, and K. Kotecha, "Domain adaptation: Challenges, methods, datasets, and applications," *IEEE Access*, vol. 11, pp. 6973–7020, 2023.
- [23] Bitbrain, "All about eeg artifacts and filtering tools," 2020, accessed: 2025-04-03. [Online]. Available: <https://www.bitbrain.com/blog/eeg-artifacts>
- [24] A. Quintero-Rincón, C. D. Giano, and H. Batatia, "Chapter 11. artefacts detection in eeg signals," in *Artefacts Detection in EEG Signals*, 2021.
- [25] M. X. Cohen, "A tutorial on generalized eigendecomposition for denoising, contrast enhancement, and dimension reduction in multichannel electrophysiology," *NeuroImage*, vol. 247, p. 118809, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1053811921010806>
- [26] X. Huang, C. Li, A. Liu, R. Qian, and X. Chen, "Eegdfus: A conditional diffusion model for fine-grained eeg denoising," *IEEE Journal of Biomedical and Health Informatics*, pp. 1–13, 2024.

- [27] A. Hamid, K. Gagliano, S. Rahman, N. Tulin, V. Tchiong, I. Obeid, and J. Picone, "The temple university artifact corpus: An annotated corpus of eeg artifacts," in *2020 IEEE Signal Processing in Medicine and Biology Symposium (SPMB)*, 2020, pp. 1–4.
- [28] A. Maiwald, L. Ackermann, M. Kalcher, and D. J. Wu, "Image-based data representations of time series: A comparative analysis in eeg artifact detection," 2023. [Online]. Available: <https://arxiv.org/abs/2401.05409>
- [29] D. Goyal and B. Pabla, "Condition based maintenance of machine tools—a review," *CIRP Journal of Manufacturing Science and Technology*, vol. 10, pp. 24–35, 2015. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1755581715000309>
- [30] M. Grandini, E. Bagli, and G. Visani, "Metrics for multi-class classification: an overview," 2020. [Online]. Available: <https://arxiv.org/abs/2008.05756>
- [31] J. Tohka and M. van Gils, "Evaluation of machine learning algorithms for health and wellness applications: A tutorial," *Computers in Biology and Medicine*, vol. 132, p. 104324, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482521001189>
- [32] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 2nd ed. O'Reilly Media, 2019. [Online]. Available: <https://www.amazon.com/dp/1492032646>
- [33] A. Botchkarev, "A new typology design of performance metrics to measure errors in machine learning regression algorithms," *Interdisciplinary Journal of Information, Knowledge, and Management*, vol. 14, p. 045–076, 2019. [Online]. Available: <http://dx.doi.org/10.28945/4184>
- [34] F. Lopes, A. Leal, M. F. Pinto, A. Dourado, A. Schulze-Bonhage, M. Dümpelmann, and C. Teixeira, "Removing artefacts and periodically retraining improve performance of neural network-based seizure prediction models," *Scientific*

- Reports*, vol. 13, no. 1, p. 5918, April 2023. [Online]. Available: <https://doi.org/10.1038/s41598-023-30864-w>
- [35] A. Mao, M. Mohri, and Y. Zhong, “Cross-entropy loss functions: Theoretical analysis and applications,” in *Proceedings of the 40th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, A. Krause, E. Brunskill, K. Cho, B. Engelhardt, S. Sabato, and J. Scarlett, Eds., vol. 202. PMLR, 23–29 Jul 2023, pp. 23 803–23 828. [Online]. Available: <https://proceedings.mlr.press/v202/mao23b.html>
 - [36] Z. Wang and A. C. Bovik, “Mean squared error: Love it or leave it? a new look at signal fidelity measures,” *IEEE Signal Processing Magazine*, vol. 26, no. 1, pp. 98–117, 2009.
 - [37] J. Shlens, “Notes on kullback-leibler divergence and likelihood,” 2014. [Online]. Available: <https://arxiv.org/abs/1404.2000>
 - [38] B. Fuglede and F. Topsøe, “Jensen-shannon divergence and hilbert space embedding,” in *International Symposium on Information Theory, 2004. ISIT 2004. Proceedings.*, 2004, pp. 31–.
 - [39] L. Zunino, F. Olivares, H. V. Ribeiro, and O. A. Rosso, “Permutation jensen-shannon distance: A versatile and fast symbolic tool for complex time-series analysis,” *Phys. Rev. E*, vol. 105, p. 045310, Apr 2022. [Online]. Available: <https://link.aps.org/doi/10.1103/PhysRevE.105.045310>
 - [40] W. Y. Peh, Y. Yao, and J. Dauwels, “Transformer convolutional neural networks for automated artifact detection in scalp eeg,” 2022. [Online]. Available: <https://arxiv.org/abs/2208.02405>
 - [41] D. Kim and S. Keene, “Fast automatic artifact annotator for eeg signals using deep learning,” in *2019 IEEE Signal Processing in Medicine and Biology Symposium (SPMB)*, 2019, pp. 1–5.
 - [42] N. Bahador, K. Erikson, J. Laurila, J. Koskenkari, T. Ala-Kokko, and J. Kortelainen, “A correlation-driven mapping for deep learning application in detecting artifacts

- within the eeg,” *Journal of Neural Engineering*, vol. 17, no. 5, p. 056018, October 2020.
- [43] H. Zhang, M. Zhao, C. Wei, D. Mantini, Z. Li, and Q. Liu, “Eegdenoisenet: a benchmark dataset for deep learning solutions of eeg denoising,” *Journal of Neural Engineering*, vol. 18, no. 5, oct 2021.
- [44] W. Sun, Y. Su, X. Wu, and X. Wu, “A novel end-to-end 1d-rescnn model to remove artifact from eeg signals,” *Neurocomputing*, vol. 404, pp. 108–121, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231220305944>
- [45] H. Zhang, M. Zhao, C. Wei, D. Mantini, Z. Li, and Q. Liu, “Eegdenoisenet: a benchmark dataset for deep learning solutions of eeg denoising,” *Journal of Neural Engineering*, vol. 18, no. 5, p. 056057, oct 2021. [Online]. Available: <https://dx.doi.org/10.1088/1741-2552/ac2bf8>
- [46] M. A. Klados and P. D. Bamidis, “A semi-simulated eeg/eog dataset for the comparison of eog artifact rejection techniques,” *Data in Brief*, vol. 8, pp. 1004–1006, Jun 2016.
- [47] A. Puce and M. S. Hämäläinen, “A review of issues related to data acquisition and analysis in eeg/meg studies,” *Brain Sciences*, vol. 7, no. 6, 2017. [Online]. Available: <https://www.mdpi.com/2076-3425/7/6/58>
- [48] V. Jurcak, D. Tsuzuki, and I. Dan, “10/20, 10/10, and 10/5 systems revisited: their validity as relative head-surface-based positioning systems,” *NeuroImage*, vol. 34, no. 4, pp. 1600–1611, Feb 2007, epub 2007 Jan 4.
- [49] K. T. Sweeney, H. Ayaz, T. E. Ward, M. Izzetoglu, S. F. McLoone, and B. Onaral, “A methodology for validating artifact removal techniques for physiological signals,” *IEEE Transactions on Information Technology in Biomedicine*, vol. 16, no. 5, pp. 918–926, Sep 2012, epub 2012 Jul 10.
- [50] M. Azhar, T. Shafique, and A. Amjad, “A convolutional neural network for the removal of simultaneous ocular and myogenic artifacts from eeg signals,”

- Electronics*, vol. 13, no. 22, 2024. [Online]. Available: <https://www.mdpi.com/2079-9292/13/22/4576>
- [51] M. Gabardi, A. Saibene, F. Gasparini, D. Rizzo, and F. A. Stella, “A multi-artifact eeg denoising by frequency-based deep learning,” 2023. [Online]. Available: <https://arxiv.org/abs/2310.17335>
 - [52] F. Lopes, A. Leal, J. Medeiros, M. F. Pinto, A. Dourado, M. Dümpelmann, and C. Teixeira, “Automatic electroencephalogram artifact removal using deep convolutional neural networks,” *IEEE Access*, vol. 9, pp. 149 955–149 970, 2021.
 - [53] E. Brophy, P. Redmond, A. Fleury, M. De Vos, G. Boylan, and T. Ward, “Denoising eeg signals for real-world bci applications using gans,” *Frontiers in Neuroergonomics*, vol. Volume 2 - 2021, 2022. [Online]. Available: <https://www.frontiersin.org/journals/neuroergonomics/articles/10.3389/fnrgo.2021.805573>
 - [54] Y. Li, A. Liu, J. Yin, C. Li, and X. Chen, “A segmentation-denoising network for artifact removal from single-channel eeg,” *IEEE Sensors Journal*, vol. 23, no. 13, pp. 15 115–15 127, 2023.
 - [55] H. Cui, C. Li, A. Liu, R. Qian, and X. Chen, “A dual-branch interactive fusion network to remove artifacts from single-channel eeg,” *IEEE Transactions on Instrumentation and Measurement*, vol. 73, pp. 1–12, 2024.
 - [56] B. J. Choi, “Removing neural signal artifacts with autoencoder-targeted adversarial transformers (at-at),” 2025. [Online]. Available: <https://arxiv.org/abs/2502.05332>
 - [57] V. Ronca, R. Capotorto, G. Di Flumeri, A. Giorgi, A. Vozzi, D. Germano, V. D. Virgilio, G. Borghini, G. Cartocci, D. Rossi, B. M. S. Inguscio, F. Babiloni, and P. Aricò, “Optimizing eeg signal integrity: A comprehensive guide to ocular artifact correction,” *Bioengineering*, vol. 11, no. 10, 2024. [Online]. Available: <https://www.mdpi.com/2306-5354/11/10/1018>
 - [58] M. Y. Sikkandar, S. Sabarunisha Begum, A. Alassaf, I. AlMohimeed, K. Alhussaini, A. Aleid, and A. K. Alhaidar, “Optimization driven variational autoencoder gan

- for artifact reduction in eeg signals for improved neurological disorder and disability assessment,” *Measurement Science Review*, vol. 25, no. 1, pp. 10–14, 2025. [Online]. Available: <https://doi.org/10.2478/msr-2025-0002>
- [59] X. Zhao, D. Liu, L. Ma, Q. Ai, Q. Liu, and S. Xie, “Eeg signals de-noising with wavelet by optimizing threshold based on fruit fly optimization,” in *Proceedings of the 2020 9th International Conference on Networks, Communication and Computing*, ser. ICNCC ’20. New York, NY, USA: Association for Computing Machinery, 2021, p. 71–77. [Online]. Available: <https://doi.org/10.1145/3447654.3447665>
- [60] X. Chen, X. Xu, A. Liu, M. J. McKeown, and Z. J. Wang, “The use of multivariate emd and cca for denoising muscle artifacts from few-channel eeg recordings,” *IEEE Transactions on Instrumentation and Measurement*, vol. 67, no. 2, pp. 359–370, 2018.
- [61] C. Bao, Z. Hao, and W. Dou, “Automatic removal of scalp eeg artifacts using an interpretable hybrid deep learning method,” in *2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 2022, pp. 1451–1456.
- [62] N. Mashhadi, A. Z. Khuzani, M. Heidari, and D. Khaledyan, “Deep learning denoising for eeg artifacts removal from eeg signals,” *2020 IEEE Global Humanitarian Technology Conference (GHTC)*, pp. 1–6, 2020. [Online]. Available: <https://api.semanticscholar.org/CorpusID:221802364>
- [63] D. Aquilué-Llorens and A. Soria-Frisch, “Eeg artifact detection and correction with deep autoencoders,” 2025. [Online]. Available: <https://arxiv.org/abs/2502.08686>
- [64] A. Babayan, M. Erbey, D. Kumral, J. D. Reinelt, A. M. F. Reiter, J. Röbbig, H. L. Schaare, M. Uhlig, A. Anwander, P.-L. Bazin, A. Horstmann, L. Lampe, V. V. Nikulin, H. Okon-Singer, S. Preusser, A. Pampel, C. S. Rohr, J. Sacher, A. Thöne-Otto, S. Trapp, T. Nierhaus, A. Altmann, K. Arelin, M. Blöchl, E. Bongartz, P. Breig, E. Cesnaite, S. Chen, R. Cozatl, S. Czerwontis, G. Dambrauskaite, M. Dreyer, J. Enders, M. Engelhardt, M. M. Fischer, N. Forschack, J. Golchert, L. Golz, C. A. Guran, S. Hedrich, N. Hentschel, D. I. Hoffmann, J. M. Huntenburg, R. Jost, A. Kosatschek, S. Kunzendorf, H. Lammers, M. E. Lauckner, K. Mahjoory, R. S. Kanaan,

- N. Mendes, R. Menger, E. Morino, K. Nätke, J. Neubauer, H. Noyan, S. Oligschläger, P. Panczyszyn-Trzewik, D. Poehlchen, N. Putzke, S. Roski, M. C. Schaller, A. Schieferbein, B. Schlaak, R. Schmidt, K. J. Gorgolewski, H. M. Schmidt, A. Schrimpf, S. Stasch, M. Voss, A. Wiedemann, D. S. Margulies, M. Gaebler, and A. Villringer, "A mind-brain-body dataset of mri, eeg, cognition, emotion, and peripheral physiology in young and old adults," *Scientific Data*, vol. 6, p. 180308, Feb 2019.
- [65] N. Agarwal, A. Mangal, S. Singiri, A. Chhapola, and S. Jain, "Self-supervised learning for eeg artifact detection," December 2022, available at SSRN: <https://ssrn.com/abstract=4982677>. [Online]. Available: <https://ssrn.com/abstract=4982677>
- [66] B. Kalita, N. Deb, and D. Das, "Aneeg: Leveraging deep learning for effective artifact removal in eeg data," *Scientific Reports*, vol. 14, no. 1, p. 24234, October 2024.
- [67] J. Yin, A. Liu, C. Li, R. Qian, and X. Chen, "A gan guided parallel cnn and transformer network for eeg denoising," *IEEE Journal of Biomedical and Health Informatics*, pp. 1–12, 2023.
- [68] W. Xiong, L. Ma, and H. Li, "A general dual-pathway network for eeg denoising," *Frontiers in Neuroscience*, vol. 17, 2024. [Online]. Available: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2023.1258024>
- [69] W. Lu, X. Zhang, L. Xia, H. Ma, and T.-P. Tan, "Jemalsubject eeg emotion recognition," *Frontiers in Human Neuroscience*, vol. 18, 2024. [Online]. Available: <https://www.frontiersin.org/journals/human-neuroscience/articles/10.3389/fnhum.2024.1471634>
- [70] N. Bahador, K. Erikson, J. Laurila, J. Koskenkari, T. Ala-Kokko, and J. Kortelainen, "Automatic detection of artifacts in eeg by combining deep learning and histogram contour processing," in *2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*, 2020, pp. 138–141.
- [71] X. Pu, P. Yi, K. Chen, Z. Ma, D. Zhao, and Y. Ren, "Eegdnet: Fusing non-local and local self-similarity for eeg signal denoising with transformer,"

- Computers in Biology and Medicine*, vol. 151, p. 106248, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482522009568>
- [72] D. Yadav, S. Yadav, and K. Veer, “A comprehensive assessment of brain computer interfaces: Recent trends and challenges,” *Journal of Neuroscience Methods*, vol. 346, p. 108918, Dec. 2020, pMID: 32853592. [Online]. Available: <https://doi.org/10.1016/j.jneumeth.2020.108918>
- [73] N. Courty, R. Flamary, A. Habrard, and A. Rakotomamonjy, “Joint distribution optimal transportation for domain adaptation,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17. Red Hook, NY, USA: Curran Associates Inc., 2017, p. 3733–3742.